




Pós-graduação em Inteligência Artificial para Desenvolvedores

Sistema de Apoio ao Diagnóstico da Síndrome dos Ovários Policísticos (SOP) com Machine Learning

Tech Challenge — Fase 1

Matheus Tomaz

mathtomaz.1@gmail.com

Repositório: github.com/matomaz/fiap-postech-tc-fase1

Maio de 2026

Entregáveis do Tech Challenge — Fase 1

Esta página reúne todos os artefatos exigidos pelo enunciado do Tech Challenge Fase 1, conforme a seção *Entregáveis da Fase 1* do documento oficial. Todos os itens obrigatórios foram desenvolvidos e estão disponíveis nos endereços abaixo.

■ LINK DO REPOSITÓRIO GIT

<https://github.com/matomaz/fiap-postech-tc-fase1>

■ LINK DO VÍDEO DE DEMONSTRAÇÃO (YouTube / Vimeo — até 15 min)

<https://www.youtube.com/watch?v=2FSHSRRuxuc>

■ LINK DO DATASET (Kaggle — PCOS)

<https://www.kaggle.com/datasets/prasoonkottarathil/polycystic-ovary-syndrome-pcos>

Resumo

Este trabalho apresenta o desenvolvimento de um sistema de apoio ao diagnóstico da Síndrome dos Ovários Policísticos (SOP) utilizando algoritmos de Machine Learning supervisionado. A SOP é um dos distúrbios endócrinos mais prevalentes em mulheres em idade reprodutiva, afetando entre 8% e 13% dessa população, mas seu diagnóstico frequentemente é tardio em virtude da variabilidade e sobreposição de sintomas com outras condições clínicas.

O estudo utilizou um dataset público coletado em 10 hospitais do estado de Kerala, Índia, contendo dados clínicos, laboratoriais e ultrassonográficos de 541 pacientes. Quatro algoritmos foram treinados e avaliados: Regressão Logística, Árvore de Decisão, Random Forest e K-Nearest Neighbors (KNN). Além dos modelos, foram aplicadas técnicas de Feature Engineering para criar variáveis clinicamente fundamentadas, bem como análise de explicabilidade por meio de SHAP values.

Os resultados indicam que a Regressão Logística obteve o maior Recall (88,89%), métrica considerada prioritária no contexto do diagnóstico médico, enquanto o Random Forest apresentou a melhor acurácia geral (93,58%) e AUC-ROC de 0,9505. O estudo conclui que esses modelos têm potencial como ferramentas de triagem clínica, desde que operados sob supervisão médica.

Palavras-chave: Síndrome dos Ovários Policísticos; Machine Learning; Diagnóstico Clínico; Feature Engineering; SHAP; Recall.

1. Introdução

O aumento do volume de pacientes em unidades de saúde especializadas no atendimento feminino cria uma demanda crescente por ferramentas que auxiliem profissionais médicos na identificação precoce de condições de risco. Nesse cenário, sistemas baseados em inteligência artificial surgem como aliados promissores, capazes de processar grandes volumes de dados clínicos e apontar padrões que, isoladamente, poderiam passar despercebidos.

A Síndrome dos Ovários Policísticos (SOP) é um dos distúrbios endócrinos mais frequentes na população feminina em idade reprodutiva, com prevalência estimada entre 8% e 13% globalmente (Teede et al., 2018). Do ponto de vista clínico, a SOP se manifesta como um conjunto heterogêneo de sinais e sintomas — irregularidade menstrual, hiperandrogenismo, ovários policísticos ao ultrassom, resistência à insulina e dificuldades de concepção —, o que torna o diagnóstico desafiador mesmo para especialistas.

O impacto da SOP vai além da esfera reprodutiva: pacientes não tratadas apresentam risco substancialmente maior de desenvolver diabetes tipo 2, doenças cardiovasculares, síndrome metabólica e transtornos de humor (Azziz et al., 2016). Por isso, a identificação precoce é particularmente relevante — cada mês de atraso no diagnóstico representa um período a mais sem intervenção terapêutica adequada.

Este trabalho, desenvolvido no contexto do Tech Challenge da primeira fase da pós-graduação em Inteligência Artificial para Desenvolvedores da FIAP POSTECH, tem como objetivo construir um sistema de classificação binária — SOP versus não-SOP — a partir de dados clínicos estruturados. Utilizando as técnicas ensinadas nas disciplinas de Machine Learning e Machine Learning Avançado, foram treinados e comparados quatro algoritmos, aplicando boas práticas de pré-processamento, validação cruzada e explicabilidade.

1.1 Justificativa da escolha do problema

Dentre as opções sugeridas no enunciado do Tech Challenge — diagnóstico de câncer de mama e detecção de SOP —, optou-se pela SOP por duas razões principais. Primeiro, o dataset disponibilizado pelo Kaggle apresenta uma variedade rica de features clínicas (hormonais, metabólicas, ultrassonográficas e comportamentais), o que permite explorar técnicas de pré-processamento e Feature Engineering de forma mais abrangente. Segundo, o problema de classificação binária com desequilíbrio moderado de classes (67% negativo, 33% positivo) oferece um contexto realista para discutir métricas como Recall, Precisão e F1-Score — temas centrais das aulas de Machine Learning Avançado.

1.2 Escopo e limitações

Este estudo é acadêmico e não substitui avaliação clínica profissional. O modelo foi desenvolvido e avaliado em dados históricos de um contexto geográfico específico (Kerala, Índia), o que implica limitações de generalização para outras populações. Todas as conclusões devem ser interpretadas como indicações para investigação adicional, não como recomendações clínicas definitivas.

2. Dataset

2.1 Fonte e descrição

O dataset utilizado neste estudo foi disponibilizado publicamente na plataforma Kaggle pelo pesquisador Prasoon Kottarathil em 2020, sob o título *Polycystic Ovary Syndrome (PCOS)*. Os dados foram coletados em 10 hospitais diferentes do estado de Kerala, Índia, e compilam informações clínicas de 541 pacientes femininas. O dataset pode ser acessado em:

<https://www.kaggle.com/datasets/prasoonkottarathil/polycystic-ovary-syndrome-pcos>

O repositório de dados é composto por dois arquivos. O primeiro, *PCOS_data_without_infertility.xlsx*, contém os dados clínicos principais com 45 colunas, sendo a coluna *PCOS (Y/N)* o target binário da classificação (0 = sem SOP, 1 = com SOP). O segundo arquivo, *PCOS_infertility.csv*, contém dados de exames adicionais. Após verificação minuciosa, constatou-se que todas as colunas do CSV já estão presentes no Excel com valores idênticos, confirmado pela diferença máxima de zero entre os valores de AMH nos dois arquivos. Por essa razão, apenas o Excel foi utilizado como fonte de dados.

2.2 Estrutura do dataset

Após remoção das colunas de identificação (*Sl. No*, *Patient File No.*) e da coluna vazia (*Unnamed: 44*), o dataset de trabalho ficou com **541 pacientes × 42 features**. As variáveis são organizadas nos seguintes grupos:

Grupo	Features
Demográficas	Idade, Peso, Altura, IMC, Tipo sanguíneo
Hormonais	FSH, LH, FSH/LH, AMH, TSH, PRL, beta-HCG I e II
Metabólicas	Glicose (RBS), Hemoglobina, PA sistólica/diastólica, Frequência cardíaca
Sintomas clínicos	Ganho de peso, crescimento de pelos, escurecimento da pele, queda capilar, acne
Ultrassonográficas	Número de folículos (E/D), tamanho médio dos folículos, espessura endometrial
Comportamentais	Consumo de fast food, prática regular de exercício
Reprodutivas	Ciclo menstrual, tempo de casamento, gestação anterior, número de abortos

Tabela 1 — Grupos de features do dataset de SOP.

2.3 Distribuição do target

O dataset apresenta um desequilíbrio moderado de classes: 364 pacientes sem SOP (67,3%) e 177 com SOP (32,7%). Esse nível de desequilíbrio, embora presente, não é severo o suficiente para exigir técnicas de reamostragem como SMOTE ou undersampling. A estratégia adotada foi o parâmetro `class_weight='balanced'` nos modelos que suportam essa opção, que ajusta os pesos dos erros proporcionalmente ao inverso da frequência de cada classe.




Figura 1 — Distribuição das 541 pacientes entre as classes sem SOP (verde) e com SOP (vermelho).

3. Análise Exploratória de Dados

A análise exploratória de dados (EDA) é o passo que precede qualquer decisão de modelagem. Nessa etapa, procura-se entender a distribuição de cada variável, identificar padrões que possam diferenciar as duas classes e detectar possíveis inconsistências nos dados. A EDA aqui realizada é orientada pelo conhecimento clínico da SOP, priorizando as features que a literatura médica aponta como marcadores relevantes.

3.1 Estatísticas descritivas gerais

O dataset é composto por 21 colunas numéricas do tipo float e 21 do tipo inteiro. A média de idade das pacientes é de 31,4 anos (dp = 5,4), com amplitude de 20 a 48 anos. O IMC médio é de 24,3 kg/m² (dp = 4,1), cobrindo desde abaixo do peso (12,4) até obesidade severa (38,9). Quanto ao ciclo menstrual, 67% das pacientes apresentam ciclos regulares (código 2 na variável) e 33% irregulares (código 5), o que já é um sinal de associação com SOP.

Em relação aos valores ausentes, o dataset é excepcionalmente limpo: apenas 4 células nulas foram encontradas, em 4 colunas distintas — *Marraige Status (Yrs)*, *II beta-HCG(mIU/mL)*, *AMH(ng/mL)* e *Fast food (Y/N)* — todas preenchidas com a mediana da respectiva coluna antes da modelagem.

3.2 Distribuição das features clínicas

A Figura 2 mostra os histogramas das oito features com maior relevância clínica para SOP, separados por diagnóstico. Os padrões visuais confirmam o que a literatura médica descreve:

O **AMH (hormônio antimülleriano)** é consistentemente mais elevado nas pacientes com SOP, refletindo a maior reserva ovariana. A **contagem de folículos** (esquerdo e direito) é claramente maior no grupo SOP, em concordância com o Critério de Rotterdam — 12 ou mais folículos por ovário é um dos três critérios de diagnóstico oficiais. A **razão FSH/LH** tende a ser menor nas pacientes com SOP, pois o LH costuma estar elevado em relação ao FSH nessa síndrome. O **IMC** apresenta distribuição ligeiramente deslocada para a direita no grupo SOP, embora a sobreposição seja considerável.

Distribuição das principais features clínicas por diagnóstico de SOP




Figura 2 — Histogramas das principais features clínicas por diagnóstico de SOP (verde = sem SOP, vermelho = com SOP).

3.3 Boxplots por grupo diagnóstico

Os boxplots da Figura 3 complementam os histogramas, evidenciando mediana, dispersão e outliers de cada feature separados por diagnóstico. Observa-se que a contagem de folículos e o AMH apresentam medianas significativamente distintas entre os grupos, o que sugere alto poder discriminativo para a classificação. A razão FSH/LH mostra dispersão elevada no grupo sem SOP, com muitos outliers, enquanto no grupo com SOP a concentração de valores é mais homogênea.

Boxplots das principais features por diagnóstico de SOP




Figura 3 — Boxplots das principais features clínicas por diagnóstico de SOP.

3.4 Prevalência de sintomas clínicos

A Figura 4 compara a prevalência de sintomas binários entre os grupos com e sem SOP. O resultado é expressivo: **ganho de peso** ocorre em aproximadamente 74% das pacientes com SOP versus 29% das sem SOP. **Crescimento de pelos** é reportado por 73% das pacientes com SOP contra apenas 19% das sem SOP. **Escurecimento da pele** — sinal clínico de hiperinsulinemia — aparece em 71% das pacientes com SOP. Esses três sintomas, em conjunto, formam um perfil visual bastante característico da síndrome.

Uma observação interessante é que o consumo de fast food e a prática de exercício físico apresentam diferenças menores entre os grupos, o que sugere que esses fatores comportamentais, embora relevantes para a saúde geral, não são determinantes isolados no diagnóstico de SOP.




Figura 4 — Prevalência percentual de sintomas clínicos nas pacientes com e sem SOP.

3.5 Análise de correlação com o target

O heatmap da Figura 5 apresenta as correlações entre as top features e o target. As correlações mais altas com *PCOS (Y/N)* são da contagem total de folículos (+0,66), seguida pelos folículos de cada ovário individualmente (+0,60 e +0,65), pela soma de sintomas (+0,58), pelo escurecimento de pele (+0,48) e pelo crescimento de pelos (+0,46). Essas correlações corroboram o conhecimento clínico e dão confiança ao modelo para usar essas features como discriminadores.




Figura 5 — Heatmap de correlação entre as top features e o target de diagnóstico de SOP.

4. Pré-processamento de Dados

O pré-processamento é a etapa que transforma os dados brutos em um formato adequado para os algoritmos de Machine Learning. Cada decisão tomada aqui tem impacto direto na qualidade das predições e deve ser justificada tanto tecnicamente quanto clinicamente.

4.1 Tratamento de valores ausentes

Como mencionado na seção anterior, apenas quatro células apresentaram valores ausentes. Para cada coluna com NaN, o valor foi substituído pela **mediana** da respectiva variável, calculada apenas sobre os dados de treino para evitar data leakage. A mediana foi escolhida em vez da média por ser mais robusta a outliers — uma preocupação legítima em dados laboratoriais como beta-HCG e AMH, que podem apresentar valores extremos em casos clinicamente atípicos.

4.2 Codificação de variáveis categóricas

O dataset é predominantemente numérico. A variável *Blood Group* já se encontrava codificada numericamente no arquivo original (valores de 11 a 18 representando os tipos sanguíneos A+, A-, B+, B-, AB+, AB-, O+, O-). As variáveis binárias de sintomas (presença/ausência) já estavam em formato 0/1. Portanto, nenhuma codificação adicional foi necessária além da já existente.

4.3 Feature Engineering

Feature Engineering é a prática de criar novas variáveis a partir das existentes, incorporando conhecimento de domínio para tornar os dados mais expressivos para os modelos. Esta etapa não é apenas técnica — ela exige entender o que cada variável significa clinicamente e como combinações de variáveis podem capturar padrões que nenhuma delas capturaria sozinha.

Foram criadas quatro novas features, descritas na Tabela 2 abaixo:

Feature criada	Descrição clínica	Correlação com SOP	Importância RF
total_foliculos	Soma dos folículos nos dois ovários (critério Rotterdam)	+0,660	18,17% (#1)
soma_sintomas	Contagem de sintomas binários simultâneos (0 a 5)	+0,580	10,25% (#3)
faixa_imc	Categorização do IMC segundo faixas clínicas da OMS	+0,165	0,48% (#29)
razao_lh_fsh	LH / FSH — valor alto indica desequilíbrio hormonal	+0,065	2,18% (#12)

Tabela 2 — Features criadas na etapa de Feature Engineering e suas correlações com o target.

A feature **total_foliculos** é derivada da soma dos folículos do ovário esquerdo e direito, diretamente relacionada ao Critério de Rotterdam — o padrão-ouro do diagnóstico de SOP. Ela ficou em primeiro lugar no Feature Importance do Random Forest, com 18,17% de importância total, superando as features individuais de cada ovário. A feature **soma_sintomas** conta quantos dos cinco sintomas binários a paciente apresenta simultaneamente, capturando o conceito de carga sintomática — pacientes com SOP tendem a acumular múltiplos sintomas ao mesmo tempo.




Figura 6 — Distribuição das quatro features criadas por diagnóstico de SOP.

4.4 Feature Selection

Após criar as novas features, foi aplicada uma seleção baseada em correlação: todas as features com correlação absoluta menor que 0,05 com o target foram removidas. Ao todo, 14 features foram descartadas — incluindo *FSH/LH*, *TSH*, *PRL*, *Pressão Arterial* e *beta-HCG* —, reduzindo o espaço de features de 45 para 31. Essa redução diminui o ruído e o risco de overfitting, tornando os modelos mais eficientes sem perder poder discriminativo.

4.5 Separação treino e teste

O dataset foi dividido em 80% para treinamento (432 pacientes) e 20% para teste (109 pacientes). A separação utilizou estratificação (*stratify=y*) para garantir que a proporção SOP/não-SOP fosse mantida em ambos os conjuntos — 32,6% de casos positivos no treino e 33,0% no teste. A semente aleatória *random_state=42* foi utilizada em todas as operações que envolvem aleatoriedade para garantir a reprodutibilidade dos resultados.

4.6 Normalização com StandardScaler

Todas as features numéricas foram normalizadas com o **StandardScaler** (z-score), que transforma cada feature para ter média zero e desvio padrão igual a um. A normalização é obrigatória para algoritmos baseados em distância (KNN) e beneficia a Regressão Logística, que assume features com escalas comparáveis. O StandardScaler foi ajustado (*fit*) exclusivamente sobre o conjunto de treino, e os parâmetros obtidos foram aplicados ao conjunto de teste, evitando qualquer contaminação dos dados de avaliação.

Optou-se pelo StandardScaler em vez do MinMaxScaler porque o dataset apresenta features hormonais com outliers relevantes — por exemplo, o beta-HCG pode atingir valores muito superiores à média em casos atípicos. O StandardScaler é menos afetado por esses valores extremos, preservando melhor a estrutura da distribuição.

5. Modelagem

Quatro algoritmos de classificação supervisionada foram treinados e comparados, cada um representando uma abordagem diferente ao problema. A escolha foi motivada pela progressão didática das aulas e pela complementaridade das técnicas: um modelo linear interpretável, um modelo baseado em regras, um ensemble e um modelo baseado em distância.

5.1 Por que Recall é a métrica prioritária?

Antes de detalhar os modelos, é necessário justificar a escolha da métrica de avaliação principal. Em diagnóstico médico, os erros não têm o mesmo custo:

Tipo de erro	O que significa	Consequência clínica
Falso Negativo (FN)	Modelo classifica como "sem SOP" uma paciente que tem SOP	Paciente não recebe tratamento — risco de diabetes tipo 2, infertilidade e doenças cardiovasculares
Falso Positivo (FP)	Modelo classifica como "com SOP" uma paciente saudável	Paciente realiza exames adicionais — indesejável, porém clinicamente menos grave

Tabela 3 — Comparação dos tipos de erro no contexto do diagnóstico de SOP.

O **Recall** (ou Sensibilidade) mede exatamente a capacidade do modelo de identificar corretamente os casos positivos: de todas as pacientes que realmente têm SOP, quantas o modelo identificou? Um modelo com Recall alto comete poucos Falsos Negativos. Por isso, maximizar o Recall é o critério primário neste estudo, mesmo que isso implique tolerar uma taxa ligeiramente maior de Falsos Positivos.

5.2 Regressão Logística

A Regressão Logística é o modelo baseline natural para classificação binária. Ela aprende um hiperplano linear no espaço das features que separa as duas classes, utilizando a função sigmoide para converter os valores de saída em probabilidades. Por ser um modelo linear e interpretável — cada coeficiente representa a contribuição de uma feature para o log-odds do diagnóstico —, a Regressão Logística é frequentemente utilizada como referência inicial em problemas médicos.

Foi utilizado `class_weight='balanced'` para compensar o desequilíbrio de classes, e o número máximo de iterações foi definido como 1000 para garantir a convergência do otimizador.

5.3 Árvore de Decisão

A Árvore de Decisão cria um conjunto de regras IF/ELSE encadeadas, dividindo recursivamente o espaço das features para maximizar a pureza de cada folha. Sua principal vantagem em contextos médicos é a **interpretabilidade**: é possível rastrear exatamente quais critérios levaram a um determinado diagnóstico, o que facilita a comunicação entre o sistema e o médico.

Para controlar o overfitting, foi definida profundidade máxima de 5 níveis (*max_depth=5*) e o critério de divisão *entropy*, que mede o ganho de informação em cada divisão. Uma árvore muito profunda decoraria os dados de treino sem generalizar para novos pacientes.

5.4 Random Forest

O Random Forest é um ensemble de 100 Árvores de Decisão independentes, cada uma treinada sobre uma amostra aleatória do dataset com reposição (bagging) e usando um subconjunto aleatório das features em cada divisão. A predição final é feita por votação majoritária das 100 árvores. Essa combinação reduz drasticamente o overfitting que uma única árvore sofreria, resultando em maior estabilidade e generalização.

O Random Forest foi o modelo escolhido para a análise de Feature Importance e SHAP values, por ser o mais robusto e por oferecer nativamente mecanismos de explicabilidade baseados na redução de impureza de Gini.

5.5 K-Nearest Neighbors (KNN)

O KNN classifica uma nova paciente pela maioria das classes entre seus *k* vizinhos mais próximos no espaço de features. A intuição clínica é direta: pacientes com perfis laboratoriais semelhantes tendem a ter o mesmo diagnóstico. Por depender de distâncias euclidianas, o KNN exige que todas as features estejam na mesma escala — e aqui que a normalização com StandardScaler se torna indispensável.

O valor de *k* foi escolhido por validação cruzada K-Fold entre *k* = 3, 5, 7, 9, 11, 13 e 15. O valor *k*=5 obteve o maior F1-Score médio (82,44%) no conjunto de treino e foi selecionado para o modelo final.

6. Resultados e Avaliação dos Modelos

6.1 Resumo comparativo

A Tabela 4 apresenta o resumo das métricas de avaliação dos quatro modelos no conjunto de teste (109 pacientes, jamais vistos durante o treinamento). Os valores em verde indicam os melhores resultados em cada métrica.

Modelo	Acurácia (%)	Recall (%)	F1-Score (%)	AUC-ROC
Regressão Logística	89,91	88,89	85,33	0,9631
Árvore de Decisão	86,24	80,56	79,45	0,8701
Random Forest	93,58	83,33	89,55	0,9505
KNN (k=5)	90,83	77,78	84,85	0,9614

Tabela 4 — Comparativo de desempenho dos quatro modelos no conjunto de teste. Valores em verde indicam o melhor resultado da métrica.

A interpretação da tabela revela trade-offs importantes. A **Regressão Logística**, apesar de ser o modelo mais simples, obteve o **maior Recall (88,89%)**, identificando corretamente 32 das 36 pacientes com SOP no conjunto de teste. Isso significa apenas 4 Falsos Negativos — um resultado notável para um modelo linear. O **Random Forest** alcançou a **maior Acurácia (93,58%)** e o **maior F1-Score (89,55%)**, porém com Recall de 83,33% (30 de 36 pacientes corretamente identificadas). O **KNN** apresentou Acurácia de 90,83% e AUC-ROC de 0,9614 — competitivo, mas com o menor Recall do grupo.

6.2 Matrizes de confusão

As matrizes de confusão da Figura 7 permitem visualizar especificamente onde cada modelo erra. A célula inferior-esquerda (Falsos Negativos — pacientes com SOP classificadas como saudáveis) é a mais crítica clinicamente. A Regressão Logística apresenta apenas 4 FN, enquanto o KNN apresenta 8 FN no conjunto de teste.




Figura 7 — Matrizes de confusão dos quatro modelos. A célula inferior-esquerda representa os Falsos Negativos (pacientes com SOP não identificadas).

6.3 Curvas ROC e AUC

A curva ROC plota a Taxa de Verdadeiros Positivos (Recall) contra a Taxa de Falsos Positivos para diferentes limiares de decisão, e a AUC (Área Under the Curve) resume essa relação em um único número. Uma AUC de 1,0 representa um classificador perfeito; 0,5 representa um classificador aleatório.

Todos os quatro modelos apresentaram AUC superior a 0,87, com a Regressão Logística alcançando a maior AUC (0,9631) e o Random Forest ficando logo atrás (0,9505). Esses valores indicam que todos os modelos têm forte capacidade discriminativa entre as duas classes, independente do limiar de decisão escolhido.




Figura 8 — Curvas ROC dos quatro modelos. A área sob a curva (AUC) indica a capacidade discriminativa geral de cada algoritmo.

6.4 Validação Cruzada K-Fold

Para avaliar a estabilidade dos modelos além do conjunto de teste, foi aplicada validação cruzada K-Fold com $k=5$ sobre o conjunto de treino. Nessa técnica, o dataset de treino é dividido em 5 partes

iguais; o modelo é treinado em 4 partes e avaliado na quinta, repetindo o processo 5 vezes. O resultado é a média e o desvio padrão do F1-Score nas 5 iterações.

Modelo	F1 médio (%)	Desvio padrão
Regressão Logística	80,34%	±4,79%
Árvore de Decisão	76,69%	±5,75%
Random Forest	82,89%	±3,25%
KNN (k=5)	82,44%	±5,68%

Tabela 5 — Validação Cruzada K-Fold (k=5) sobre o conjunto de treino.

O **Random Forest** obteve o maior F1-Score médio na validação cruzada (82,89%) com o menor desvio padrão (±3,25%), indicando ser o modelo mais estável e consistente entre as iterações. A **Árvore de Decisão** apresentou o maior desvio padrão (±5,75%), revelando mais variabilidade entre as dobras.

7. Explicabilidade do Modelo

Modelos de Machine Learning aplicados à saúde não podem ser simplesmente caixas-pretas. Médicos e pacientes precisam entender o que motivou um determinado diagnóstico — tanto para validar a lógica clínica quanto para identificar eventuais falhas ou viés. Duas técnicas complementares foram utilizadas para explicar as previsões do Random Forest: Feature Importance e SHAP Values.

7.1 Feature Importance (Random Forest)

A Feature Importance do Random Forest mede a contribuição média de cada feature para a redução da impureza de Gini ao longo de todas as 100 árvores. Quanto maior o valor, mais aquela feature foi usada para fazer divisões importantes na estrutura das árvores.




Figura 9 — Feature Importance do Random Forest. Features em rosa foram criadas na etapa de Feature Engineering; features em cinza são originais do dataset.

O resultado é revelador: a feature criada **total_foliculos** ficou em primeiro lugar (18,17%), superando as features originais de cada ovário individualmente (Follicle No. R com 14,91% e Follicle No. L com 8,61%). Isso confirma que a combinação dos dados de ambos os ovários é mais informativa do que analisar cada lado separadamente — o que faz sentido clínico, já que o Critério de Rotterdam avalia a contagem total.

A feature **soma_sintomas** ficou em terceiro lugar (10,25%), demonstrando que a carga sintomática cumulativa tem alto poder discriminativo. O AMH aparece em sexto lugar (3,48%), confirmando sua importância como marcador hormonal da SOP, mesmo sendo uma feature laboratorial com mais variabilidade individual.

7.2 SHAP Values (SHapley Additive exPlanations)

SHAP é uma técnica de explicabilidade fundamentada na teoria dos jogos cooperativos (Shapley, 1953), adaptada para Machine Learning por Lundberg e Lee (2017). Para cada predição, o SHAP calcula a contribuição de cada feature para o afastamento em relação ao valor base do modelo. Features com SHAP positivo empurram a predição em direção a SOP; features com SHAP negativo empurram em direção a não-SOP.




Figura 10 — SHAP Summary Plot: cada ponto representa uma paciente. A posição horizontal indica a direção e magnitude do impacto da feature na predição. A cor indica o valor da feature (vermelho = alto, azul = baixo).

O SHAP Summary Plot da Figura 10 é particularmente informativo. Para a feature **total_foliculos**, pontos vermelhos (alta contagem de folículos) estão concentrados na direção positiva (SHAP > 0), o que significa que pacientes com muitos folículos recebem maior probabilidade de SOP — exatamente o que a clínica espera. Para **soma_sintomas**, o padrão é semelhante: mais sintomas correlacionam com maior SHAP positivo.




Figura 11 — SHAP Bar Plot: importância média absoluta de cada feature no conjunto de teste.

A Figura 12 apresenta um SHAP Waterfall para uma paciente específica do conjunto de teste. Esse tipo de gráfico permite rastrear individualmente o raciocínio do modelo: partindo do valor base (probabilidade média de SOP no dataset), cada feature adiciona ou subtrai probabilidade até chegar à predição final.




Figura 12 — SHAP Waterfall para uma paciente individual: mostra as contribuições de cada feature para a predição final do modelo.

8. Discussão Crítica

8.1 Os modelos podem ser usados na prática clínica?

A resposta curta é: **sim, como ferramenta de apoio, com ressalvas importantes**. Os resultados obtidos — especialmente o Recall de 88,89% da Regressão Logística e a AUC de 0,9631 — indicam que esses modelos têm capacidade real de auxiliar na identificação de pacientes em risco. Em uma unidade de saúde com alto volume de atendimentos, um sistema de triagem automatizado poderia sinalizar casos suspeitos para investigação prioritária, reduzindo o tempo até o diagnóstico definitivo.

No entanto, é fundamental reafirmar: **o médico sempre tem a palavra final**. O modelo não faz diagnóstico — ele calcula uma probabilidade. A decisão clínica final deve incorporar dados que o modelo não tem acesso, como o histórico familiar, o exame físico, o contexto social da paciente e a experiência do profissional. Um Recall de 88,89% significa que aproximadamente 1 em cada 9 pacientes com SOP ainda seria classificada como saudável pelo modelo — uma taxa não nula de Falsos Negativos que só pode ser mitigada pela avaliação médica.

8.2 Vantagens de cada modelo por contexto

Cada algoritmo tem vantagens em cenários diferentes. Em uma unidade de triagem de alto volume, onde o objetivo é capturar o máximo possível de casos positivos, a **Regressão Logística** é a escolha mais segura por seu Recall superior. Em um contexto onde a explicabilidade direta ao médico é prioritária — por exemplo, num prontuário eletrônico que precisa justificar cada alerta —, a **Árvore de Decisão** gera regras IF/ELSE fáceis de interpretar e comunicar. Para um sistema de apoio ao diagnóstico mais geral, com necessidade de balancear Acurácia, F1-Score e Explicabilidade (via SHAP), o **Random Forest** é a escolha mais equilibrada.

8.3 Limitações do estudo

Algumas limitações precisam ser reconhecidas de forma transparente. A primeira é o **tamanho do dataset**: 541 pacientes é um número modesto para treinar e validar modelos de saúde que serão usados em populações diversas. Modelos treinados em amostras pequenas podem ter mais variabilidade de desempenho quando expostos a dados de novos hospitais ou regiões.

A segunda limitação é a **origem geográfica restrita**: todos os dados vêm de hospitais de Kerala, Índia. Diferenças genéticas, ambientais, alimentares e socioeconômicas entre populações podem alterar as distribuições das features e, consequentemente, o desempenho dos modelos em outras regiões.

A terceira limitação diz respeito aos **dados de ultrassom**, que dependem do equipamento e da habilidade do operador. A contagem de folículos — a feature mais importante dos modelos — pode

variar significativamente entre diferentes ecografistas e aparelhos, introduzindo ruído sistêmico que os modelos não conseguem corrigir.

Por fim, o estudo foi realizado em dados retrospectivos, sem validação prospectiva em ambiente clínico real. O desempenho em produção — onde os dados chegam com latência, inconsistências e formatos variados — pode ser diferente do desempenho em datasets curados para pesquisa.

9. Conclusão

Este trabalho demonstrou que é possível construir um sistema de apoio ao diagnóstico da Síndrome dos Ovários Policísticos com desempenho clinicamente relevante a partir de dados clínicos estruturados e algoritmos clássicos de Machine Learning. O pipeline completo — desde a carga dos dados até a explicabilidade das predições — foi implementado em Python com boas práticas de engenharia de dados e reprodutibilidade.

Dentre os quatro modelos avaliados, a Regressão Logística se destacou pelo maior Recall (88,89%), identificando corretamente 32 das 36 pacientes com SOP no conjunto de teste. O Random Forest apresentou a melhor acurácia geral (93,58%) e o maior F1-Score (89,55%), além de oferecer mecanismos nativos de explicabilidade via Feature Importance e SHAP. O KNN demonstrou ser uma alternativa competitiva, enquanto a Árvore de Decisão trouxe o benefício adicional de gerar regras interpretáveis.

A etapa de Feature Engineering foi um dos destaques metodológicos do trabalho. As quatro features criadas — especialmente *total_foliculos* e *soma_sintomas* — não apenas melhoraram a interpretabilidade do modelo como ficaram entre as mais importantes segundo o Random Forest e o SHAP. Isso ilustra como o conhecimento clínico de domínio, combinado com técnicas de ML, pode gerar insights mais ricos do que qualquer um dos dois isoladamente.

Em suma, os resultados reafirmam o potencial da Inteligência Artificial como aliada — e não substituta — do profissional de saúde. Ferramentas desse tipo, quando bem desenvolvidas, validadas e utilizadas com transparência, têm capacidade real de acelerar triagens, reduzir atrasos diagnósticos e, em última instância, melhorar a qualidade de vida de milhões de mulheres que convivem com a SOP sem saber.

10. Referências

- AZZIZ, R. et al. Polycystic ovary syndrome. *Nature Reviews Disease Primers*, v. 2, p. 16057, 2016.
- KOTTARATHIL, P. *Polycystic Ovary Syndrome (PCOS) Dataset*. Kaggle, 2020. Disponível em: <https://www.kaggle.com/datasets/prasoonkottarathil/polycystic-ovary-syndrome-pcos>. Acesso em: 03 mai. 2025.
- LUNDBERG, S. M.; LEE, S. I. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, v. 30, 2017.
- PEDREGOSA, F. et al. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.
- SHAPLEY, L. S. A value for n-person games. *Contributions to the Theory of Games*, v. 2, p. 307-317, Princeton University Press, 1953.
- TEEDE, H. J. et al. Recommendations from the international evidence-based guideline for the assessment and management of polycystic ovary syndrome. *Human Reproduction*, v. 33, n. 9, p. 1602-1618, 2018.
- BREIMAN, L. Random forests. *Machine Learning*, v. 45, n. 1, p. 5-32, 2001.
- COVER, T. M.; HART, P. E. Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, v. 13, n. 1, p. 21-27, 1967.
- HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. *The Elements of Statistical Learning*. 2. ed. New York: Springer, 2009.