

ANA RAQUEL FERNANDES CUNHA

POSTECH

IA PARA DEVS

IAs GENERATIVAS

AULA 01

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	15
REFERÊNCIAS.....	16

EMSE

O QUE VEM POR AÍ?

Estamos vivendo uma **nova era da inteligência artificial**, e a famosa “**Inteligência Artificial Generativa**” tem ganhado muita atenção nos últimos tempos devido a sua incrível capacidade de gerar conteúdos de forma inteligente e automatizada. Nesta aula, você vai aprender qual é a “mágica” que acontece por trás dos panos da IA Generativa e quais são os principais tipos existentes no mercado. Vamos lá?



HANDS ON

Que tal mergulhar no incrível mundo da IA Generativa? Nas videoaulas, te convidamos a conhecer mais sobre essa tecnologia que tem ganhado a atenção do mundo tech. Vamos conhecer a história e como é o funcionamento da geração de conteúdo utilizando ferramentas práticas de IA disponíveis no mercado!

EMANDA

SAIBA MAIS

Entendendo sobre a IA generativa: o grande hype da inteligência artificial!

“A IA generativa, ou inteligência artificial generativa, é como um artista super criativo que usa o poder da computação para criar coisas novas e incríveis! Imagine um pintor que, em vez de copiar um quadro, inventa pinturas totalmente originais. É assim que a IA generativa funciona.

Ela é treinada com uma enorme quantidade de dados, como textos, imagens, músicas ou códigos e, ao analisar esses dados, a IA aprende os padrões e as características do que está vendo. Depois, usando esses conhecimentos, ela consegue gerar novos conteúdos!”

Sim, e todo esse trecho que você acabou de ler, foi gerado pela IA generativa do Google, o Gemini!




Figura 1 - Gemini da Google
Fonte: elaborado pela autora (2024)

Incrível, né? Para começarmos bem essa aula de introdução, eu pedi para a IA generativa do Google gerar uma explicação simples e fácil de ser compreendida sobre “o que é a IA generativa”. Ao utilizar analogias com pintor e arte, você percebeu

como a IA retornou um conteúdo simples e fácil de ser compreendido? Isso porque no **prompt de input** (instrução da geração do conteúdo), eu escrevi as seguintes palavras: “Me explique o que é a IA generativa de **forma simples e rápida**”.

Observe que a IA levou em consideração as palavras simples e rápida para gerar o conteúdo, e esse é o grande diferencial desses modelos generativos: a compreensão semântica de palavras, ou seja, a compreensão do significado e contexto de cada palavra dado uma sequência de palavras. É como se eu estivesse conversando com um humano, já que a IA demonstrou um comportamento cognitivo de entender cada palavra e seus relacionamentos semânticos no meu prompt de entrada.

Pareceu muito confuso? Não se preocupe, pois durante esta disciplina, você vai conhecer em detalhes todas as técnicas e instruções que podemos passar para esses modelos, as chamadas “**engenharias de prompts**” e todo o funcionamento técnico que acontece por “trás dos panos” do modelo. Neste momento, te convidamos a conhecer o mundo da IA generativa!

A IA generativa tem a capacidade de criar conteúdos a partir de um conteúdo de dados pré-existent. Por trás desses modelos generativos, basicamente temos os famosos **modelos de deep learning**, que são treinados com **uma grande amostra de dados** para aprender muito bem os padrões a fim de criar conteúdos a partir do aprendizado capturado pelas redes neurais. As possibilidades são muitas! Podemos criar textos, imagens, poemas, músicas, códigos e muitas outras coisas! Usando um prompt de texto como entrada para o modelo, veja um exemplo da utilização da IA generativa para a criação de imagens.



Figura 2 - Imagem criada a partir do prompt: 90's beautiful girl with long straight black hair using computer

Fonte: elaborado pela autora na IA: <https://beta.dreamstudio.ai/generate> (2024)

Legal, né? Essa imagem eu gerei a partir do texto “90's beautiful girl with long straight black hair using computer”. Veja que interessante como a IA compreendeu até o estilo de animação que eu solicitei com a estética das animações dos anos 90. Existem muitas ferramentas de IA sendo desenvolvidas por muitas empresas, e por como esse tipo de tecnologia se tornou o centro das atenções, muitas empresas estão começando a investir fortemente no desenvolvimento de seus próprios produtos de inteligência artificial. Empresas como a **Open IA**, **Google** e **Microsoft** têm sido

referências nessas tecnologias. Vamos entender um pouco sobre a história da evolução dos modelos de IA generativas?

Conhecendo a evolução da IA generativa

Quando falamos de modelos de deep learning, (na qual a IA generativa faz parte), estamos falando de teorias e estudos iniciados nos anos 40 pelo neurofisiologista Warren McCulloch e pelo matemático Walter Pitts em seu artigo de referência “Logical Calculus of Ideas Immanent in Nervous Activity”.

Neste artigo, McCulloch e Pitts apresentam um modelo computacional simplificado utilizando lógica proposicional de como os neurônios biológicos podem trabalhar juntos em cérebros de animais na realização de cálculos complexos. Inicialmente foi proposto o modelo perceptron (um modelo de neurônio de uma única camada de rede neural) e em seguida as redes neurais foram ficando cada vez mais complexas entre as décadas de 50 até 90, sendo desenvolvidas as redes multilayer perceptron (modelo de rede neural com multicamadas), as redes convolucionais (essenciais para o processamento de imagens) e as redes neurais recorrentes (utilizada no processamento de sequências e linguagem natural).

Depois do chamado “Inverno da IA” que aconteceu nos anos 90, nos anos 2000 iniciaram os desenvolvimentos das GPUs, possibilitando toda a implementação de modelos de redes neurais mais complexos, e então os estudos avançaram para os modelos da ImageNet. Com a possibilidade de avanços tecnológicos em processamento e dados para treinar as redes neurais, foi possível desenvolver os modelos de IA Generativa que conhecemos na atualidade.

Em 2012, tivemos avanços da deep learning em conjunto de dados maiores que levaram ao desenvolvimento dos modelos **GPT** (ou Transformadores Pré Treinados Generativos). O Google foi a empresa pioneira na IA generativa. Em 2012, o Google lançou o modelo **BERT** (Bidirectional Encoder Representation from Transformers), que foi um grande salto na arquitetura e que abriu portas para os modelos futuros que conhecemos hoje. Em 2020, a OpenAI lançou o **GPT-3**, que se tornou o maior modelo com 175 bilhões de parâmetros e, em 2022, esses modelos de LLM (Large Language Models) se tornaram mais acessíveis pelos usuários por meio de uma interface web. Você pode acessar esse modelo [aqui](#). Desde 2022 até os dias

de hoje, muitas empresas estão lançando várias IA generativas e melhorias de versões anteriores para deixar o modelo cada vez mais robusto.

Exemplos de IA generativas:

- DALL-E;
- Midjourney;
- Copilot;
- GPT-3 e GPT-4;
- Jasper;
- Bing Chat;
- Google Gemini;
- ChatGPT.

Entendendo o funcionamento da GANs

Quando aprendemos sobre os modelos de aprendizado supervisionados tradicionais, é porque estamos querendo treinar os algoritmos em uma base de dados rotulada, a fim de ensiná-lo sobre quais são os melhores dados de características para discriminar as variáveis target. Os algoritmos generativos tentam prever os recursos (dados) com um determinado rótulo.

Por exemplo, dado que um e-mail é classificado com spam, qual é a probabilidade de palavras que formam esse e-mail serem spam? Os algoritmos discriminativos se preocupam com a **correlação entre x e y**, modelos generativos se preocupam em **“como você obterá x”**. Basicamente as GANs (Redes Adversárias Generativas) são compostas por duas redes, a geradora e a discriminante. Elas são chamadas de adversárias porque essas duas redes tentam “jogar” uma com a outra o tempo todo. A rede geradora tenta enganar a rede discriminante gerando dados fakes semelhantes aos dados reais.




Figura 3 - Arquitetura redes GANs

Fonte: <https://www.deeplearningbook.com.br/introducao-as-redes-adversarias-generativas-gans-generative-adversarial-networks/> (2022)

Vamos utilizar como exemplo, a clássica base do MNIST, de dígitos gerados à mão. O objetivo da rede discriminante é reconhecer que os dígitos gerados à mão são os mais próximos possíveis dos verdadeiros números. A rede geradora tenta criar novas imagens fakes com a esperança de torná-las autênticas também (mesmo sendo falsas). O funcionamento da rede consiste nas seguintes etapas: o gerador considera números aleatórios e retorna uma imagem (ou seja, cria uma imagem fake); essa imagem fake gerada pelo gerador é inserida no discriminador ao lado do fluxo de imagens verdadeiras geradas; o discriminador obtém imagens reais e falsas retornando a probabilidade e realizando previsões de imagens falsas geradas pela rede generativa.




Figura 4 - Funcionamento de uma rede GAN

Fonte: <https://www.deeplearningbook.com.br/introducao-as-redes-adversarias-generativas-gans-generative-adversarial-networks/> (2022)

Podemos dizer que a rede geradora é uma rede neural convolucional inversa. Enquanto um classificador padrão reduz a amostragem para produzir a probabilidade, o gerador pega um vetor de ruído aleatório e faz o upsample (operação usada para aumentar o tamanho espacial de um tensor de saída) para uma imagem. O primeiro joga fora os dados por meio de técnicas de downsampling (processo de redução do tamanho espacial (resolução) de um tensor de saída) e o segundo gera novos dados. Ambas as redes (geradora e discriminante) utilizam a função de custo para tentar minimizar o erro. À medida que o discriminador muda seu comportamento, o gerador também muda e vice-versa.




Figura 5 - Exemplo funcionamento rede GANs

Fonte: <https://blogs.mathworks.com/deep-learning/2021/12/02/synthetic-image-generation-using-gans/> (2021)

Entendendo as LLMs (Large Language Models)

Agora que compreendemos como funciona uma rede geradora de imagens, vamos comentar sobre as IA generativas de **LLM (Large Language Models)** para processar texto e gerar conteúdos a partir desse prompt de texto. A magia dos LLMs reside em modelos de linguagem que foram treinados em **quantidades massivas de dados textuais**, como livros, artigos, notícias e todos os dados disponíveis na internet. Por meio de um processo complexo de aprendizado de deep learning, os LLMs identificam padrões e regras da linguagem, permitindo-lhes realizar diversas tarefas.

Essa arquitetura de modelos de LLM são baseados nos chamados modelos **Transformers**, introduzida no artigo [“Attention is All You Need”](#) de Vaswani (2017).

A arquitetura Transformer se tornou um padrão para modelos de linguagem de última geração (LLMs) devido à sua **capacidade de processar sequências de texto de forma eficaz e capturar relacionamentos de longo alcance entre palavras (semântica)**. Mais adiante, você vai compreender o porquê esse modelo de LLM revolucionou as chamadas **redes neurais recorrentes**. Observe a imagem a seguir para compreender o funcionamento de um modelo transformer:




Figura 6 - Como funciona um modelo Transformer
Fonte: elaborado pela autora (2024)

Ao contrário de modelos tradicionais que processam as palavras uma a uma, o mecanismo de autoatenção funciona como uma teia de aranha: ele conecta cada palavra com todas as outras na frase, criando um mapa de relações complexas. Isso permite que o modelo compreenda o contexto completo da frase e determine o significado de cada palavra com base em seu papel dentro da frase (contexto).

No exemplo "Eu vou extrair os insights no banco de dados", o mecanismo de autoatenção conecta a palavra "dados" com "banco" e "insights" instantaneamente. Ele reconhece que "dados" nesse contexto se referem ao banco de dados, e não a dados de um jogo de tabuleiro. Essa capacidade de entender a relação entre as palavras é crucial para a compreensão precisa da linguagem.

Para aprofundar essa compreensão, o modelo utiliza a técnica de **embeddings**, que transforma as palavras em vetores numéricos. Esses vetores

representam o significado semântico de cada palavra, permitindo que o modelo compare o significado de palavras diferentes e identifique relações entre elas.

Em outras palavras, o modelo cria um "dicionário" de significados, onde cada palavra é representada por um vetor único. Ao comparar esses vetores, o modelo pode determinar se duas palavras têm significados relacionados ou não. Essa combinação de autoatenção e embeddings permite que o modelo compreenda a linguagem com um nível de sofisticação nunca antes visto. Ele pode desvendar o significado de frases complexas, identificar nuances sutis e até mesmo gerar textos criativos e originais. Para mais detalhes deste modelo, dê uma olhadinha em alguns testes que eu fiz neste [artigo](#).


Aplicação dos modelos generativos

E onde está sendo utilizada a IA generativa nas empresas? As aplicações são muitas, mas podemos citar exemplos como:

- **Chatbots e assistentes virtuais** para dar suporte aos clientes;
- **Análise de sentimento**: os modelos são utilizados para auxiliar opiniões de clientes sobre um determinado produto;
- **Tradução de idiomas**: utilização de modelos generativos para traduzir documentos;
- **Criação de resumos**: resumo de reuniões e documentos;
- **Geração de conteúdo**: geração de esboço de textos para as empresas gerarem uma ação de marketing, criar novos produtos e muito mais;
- **Geração ou correção de imagens**: criação de imagens a partir de algum estilo já existente ou criação de imagens totalmente originais. O estúdio Pixar, utiliza muito as redes GANs para o aumento de resolução de imagens.

A pesquisa do State of Data 2023, na qual foram coletados dados da utilização dessa tecnologia nas empresas, mostrou que 62,5% das empresas a IA generativa é uma tecnologia que está sendo trabalhada.

Figura 36: Estado atual de IA generativa na empresa onde trabalha



Nota: Desconsidera respondentes que se consideram desempregados, apenas estudantes e que preferiram não informar a situação atual de trabalho. Fonte: Pesquisa State of Data Brasil 2023

Figura 7 - Estado a IA generativa nas empresas
Fonte: State of Data (2023)

A pesquisa mostra que, os principais motivos para as empresas ainda não estarem utilizando as ferramentas de IA generativa são a falta de compreensão dos casos de usos (33,2% das respostas), falta de conhecimento e recursos (31,7% das respostas), preocupação com a segurança e privacidade dos dados (na qual podem ser aferidas pela lei geral de proteção aos dados LGDP) (30,1% das respostas), e também que algumas empresas não estão prontas para o uso da IA generativa (27,5% das respostas).

Por fim, os dados da pesquisa também revelaram que 82% dos profissionais de dados indicam que utilizam as ferramentas de IA generativa no seu dia a dia de trabalho. Entretanto, esta utilização ainda é realizada por conta própria e por meio de soluções gratuitas (67% das respostas), enquanto apenas 7% das respostas indicam que as empresas fornecem soluções pagas com foco em produtividade para os profissionais.

O QUE VOCÊ VIU NESTA AULA?

Esta aula foi uma grande imersão no mundo da IA generativa para que você possa conhecer os principais modelos generativos e como eles são utilizados no mercado.

EMEND

REFERÊNCIAS

- CUNHA, A. R. F. Conhecendo os parâmetros de uma LLM. **Medium**. 2024. Disponível em: <https://medium.com/@anaraquel.fiap/conhecendo-os-par%C3%A2metros-de-uma-llm-492dbb82a347>. Acesso em: 05 jun. 2024.
- GOODFELLOW, I. J. et al. Generative Adversarial Nets. **Université de Montreal**. 2014. Disponível em: <https://arxiv.org/pdf/1406.2661>. Acesso em: 05 jun. 2024.
- GOYAL, S. GANs – A Brief Introduction to Generative Adversarial Networks. **Medium**. 2019. Disponível em: <https://medium.com/analytics-vidhya/gans-a-brief-introduction-to-generative-adversarial-networks-f06216c7200e>. Acesso em: 05 jun. 2024.
- INTRODUÇÃO às Redes Adversárias Generativas (GANs – Generative Adversarial Networks). **Deep Learning Book**. 2022. Disponível em: <https://www.deeplearningbook.com.br/introducao-as-redes-adversarias-generativas-gans-generative-adversarial-networks/>. Acesso em: 05 jun. 2024.
- SPADINI, S. A. O que é IA Generativa? A importância e o uso das Inteligências Artificiais como ChatGPT, MidJourney e outras. **Alura**. 2023. Disponível em: <https://www.alura.com.br/artigos/inteligencia-artificial-ia-generativa-chatgpt-gpt-midjourney>. Acesso em: 05 jun. 2024.
- STATE of Data – Brazil 2023. Disponível em: <https://stateofdata.datahackers.com.br/>. Acesso em: 05 jun. 2024.
- UM guia compacto sobre Large Language Models (LLM). **Databricks**. 2023. Disponível em: <https://www.databricks.com/sites/default/files/2023-10/compact-guide-to-large-language-models-ptbr.pdf>. Acesso em: 05 jun. 2024.

PALAVRAS-CHAVE

IA Generativa. GPT. LLMs. GANs.

EMAP



POSTECH