

IA PARA DEVS

IAs GENERATIVAS

AULA 05

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	11
REFERÊNCIAS.....	12

EMSE

O QUE VEM POR AÍ?

Ao mesmo tempo em que as IA generativas trouxeram uma grande revolução para a área de inteligência artificial, elas também trouxeram muita discussão a respeito da privacidade e segurança dos dados. Nesta aula, vamos discutir sobre os desafios éticos da IA generativa na criação de conteúdo.

EMENDAS

HANDS ON

Nesta videoaula, vamos discutir sobre os desafios da IA generativa a respeito das questões de segurança, privacidade e direitos autorais.

EMSE

SAIBA MAIS

Considerações éticas sobre a IA generativa

Sempre que uma nova tecnologia é lançada, normalmente as pessoas ficam um pouco desconfiadas e até mesmo com um certo receio de como serão os próximos passos e suas possíveis consequências, e foi assim que aconteceu com o lançamento dos modelos generativos. Desde o lançamento do ChatGPT no final do ano de 2022, muitas pessoas acreditaram que poderiam perder seus empregos por conta de toda robustez dos modelos generativos. Bem, depois de todo o conhecimento obtido nessa disciplina, você já deve concordar comigo que isso não é verdade.

O que acontece é que vamos precisar cada vez mais de pessoas que saibam trabalhar nessa nova cultura AI Driven. Vamos precisar de profissionais que saibam construir esses modelos para gerar conteúdos para as empresas e negócios, e vamos precisar de pessoas utilizando essas ferramentas no seu dia-a-dia, como disse Scott Galloway (professor da Universidade de New York): “A IA não vai roubar o seu emprego, mas alguém que saiba usar vai”. Mas tem um ponto de atenção em toda essa nova era que estamos vivenciando, que é a questão ética do uso desses modelos.

Conforme você aprendeu nas aulas anteriores, os modelos generativos precisam de muitas amostras de treinamentos, pois quanto mais dados, melhor será a precisão do resultado de prompt desses modelos. Porém, essa coleta absurda de dados pode impactar a privacidade de usuários e o modelo pode acabar acessando dados sensíveis protegidos por direitos autorais. A maior parte dessa grande amostra de dados que é utilizada para treinar os modelos generativos veio da internet por meio da técnica de web scraping (mineração de dados da web) que consiste em “varrer” dados de várias páginas de sites da web a fim de coletar e extrair textos e imagens.

Uma polêmica surgiu quando a rede social X (antiga Twitter) bloqueou a visualização de mensagens para usuários não logados na plataforma e limitou o número de mensagens que podem ser lidas de forma diária. O próprio Elon Musk afirmou que o principal motivo dessas restrições seria o excesso de robôs de IA que estariam minerando as mensagens da plataforma para treinar modelos de aprendizado de máquina, a ponto de afetar de forma negativa a rede social. A

plataforma de fóruns Reddit criou limitações equivalentes em sua API, referindo principalmente à extração de dados por robôs de IA. Bem, esse mundo de IA generativa ainda é muito novo e, até a escrita desta aula, ainda não existe regulamentação específica sobre o assunto. A Google alterou sua política de privacidade para incluir que seus serviços de IA, poderão coletar dados da internet para realizar o treinamento de seus algoritmos.

A Open IA não confirma exatamente de onde vieram os dados minerados pelos seus robôs, mas eles habilitaram uma opção que permite que qualquer dono de uma página da web bloqueie o acesso desses robôs a seus conteúdos. Imagine se você colocasse dados privados da sua empresa no modelo do Chat GPT3.5 para te auxiliar com alguma tarefa em seu dia a dia? Com certeza o modelo pegaria seu prompt de input e utilizaria como treino para aprender e coletar informações desses dados fornecidos.

Por conta desse perigo de vazamento de dados, algumas empresas como Amazon, Apple, Samsung, Banco JP Morgan e entre outras, proibiram o uso do ChatGPT e IAs similares para os funcionários, a fim de proteger os dados da empresa e para não haver vazamento de dados. De qualquer forma, o uso dessas tecnologias acaba por ser uma questão de confiança de que as empresas por trás desses modelos não estejam armazenando os dados.

Além da questão da privacidade dos dados, a segurança também é um ponto de atenção superimportante nessa história. Ataques como “adversarial attacks” e “prompt injection” são técnicas que buscam enganar sistemas de IA por meio de implementação de entradas mal-intencionadas para induzir o modelo a tomar uma decisão errada.

Muitos desses perigos podem ser mitigados ou eliminados por meio da criação de regulamentações específicas para o uso de IA. O próprio CEO da Open IA, Sam Altman, se mostrou a favor dessas criações de leis perante a entrevistas e ao Congresso dos Estados Unidos. Ele sugeriu três pontos a favor da criação dessas regulamentações:

- Criação de uma agência federal responsável por conceder licenças para modelos de IA com capacidade superior a certo limite e revogá-las caso as empresas não se adequem às diretrizes de segurança estabelecidas;

- Criação de padrões de segurança de modelos de IA, garantindo a precisão da informação e que o conteúdo gerado não seja enganoso;
- Auditorias independentes de especialistas não afiliados aos criadores dos modelos ou ao governo, a fim de garantir que as ferramentas funcionem dentro das diretrizes.

Direitos autorais

Mais uma polêmica que se popularizou na mídia é sobre a criação de imagens a partir de prompts de textos, como é realizado nas ferramentas do Midjourney, o DALL-E e o Stable Diffusion. A criação de imagens extremamente realistas traz um certo desconforto, além da possibilidade de criação de imagens com algum estilo existente de artistas. Veja alguns exemplos gerados pelo Midjourney:



Figura 1 - Imagem de um homem velho coberto de chantilly gerada por meio do Midjourney
Fonte: Inteligência Artificial e ChatGPT: da revolução dos modelos de IA generativa à Engenharia de Prompt [s.d.]



Figura 2 - Imagem de um gato com traje espacial em um campo de girassóis no estilo de Van Gogh gerada por meio do Midjourney
Fonte: Inteligência Artificial e ChatGPT: Da revolução dos modelos de IA generativa à Engenharia de Prompt [s.d.]

Ao contrário dos outros sistemas mencionados, a equipe da Stability AI, por trás do Stable Diffusion, optou por um caminho transparente no treinamento de seu modelo. Graças a essa abertura, o blogueiro estadunidense Andy Baio pôde analisar os dados utilizados e concluir que a maioria das imagens provém de comunidades on-line de compartilhamento de imagens, como Pinterest, Flickr, Tumblr e DeviantArt. Além disso, também foram utilizadas imagens de blogs hospedados no WordPress e de bancos de imagens populares, como Getty Images e Shutterstock.

As plataformas on-line mencionadas, como Pinterest, Flickr, Tumblr e DeviantArt, servem como palco para a expressão artística de pessoas do mundo inteiro. Lá, artistas compartilham suas criações com o público, permitindo que sua arte seja vista e apreciada por uma comunidade global. No entanto, essa abertura levanta uma questão crucial: o compartilhamento on-line concede automaticamente o direito de usar essas obras para treinar modelos de inteligência artificial?

A resposta, infelizmente, não é simples. Embora as obras estejam disponíveis publicamente na internet, isso não significa que os artistas tenham consentido explicitamente com seu uso para o treinamento de IA. Essa distinção é fundamental para garantir o respeito aos direitos autorais e à autonomia dos artistas. Vários artistas vieram à público para dizer que os modelos de IA generativa foram treinados sem autorização prévia de suas obras. Alguns deles se juntaram e em uma ação judicial coletiva, foram contra a Midjourney e a Stability AI, afirmando que o uso dessas imagens seria uma violação dos direitos de propriedade intelectual.

Pensando em uma possível alternativa para treinar esses modelos generativos de imagem, uma delas seria o uso de banco de dados totalmente públicos e sem direitos autorais, repassando assim uma porcentagem do valor acordado para os artistas que aceitassem ter suas imagens usadas no treinamento desses modelos.

Fake News

Conversamos um pouco sobre as fake news na aula de GANs e vamos abrir mais esse assunto nesta aula de ética, já que as fake news são conteúdos falsos ou

distorcidos e que são compartilhados com o público com o intuito de manipular ou desinformar a opinião pública. A fake news de fato sempre existiu, porém agora com o uso da IA generativa, ficou mais fácil gerar conteúdos falsos, inclusive com imagens, vídeos e até mesmo áudio.

Um estudo feito pela página NewsGuard, em 2023, detectou 50 sites de notícias que estavam publicando diariamente centenas de artigos gerados pela inteligência artificial generativa com o intuito de ganhar dinheiro com propagandas. Um desses sites tinha afirmado, por exemplo, que o presidente dos Estados Unidos, Joe Biden, teria falecido em abril de 2023 e que o vice-presidente teria assumido a presidência em seu lugar. No Brasil, a página Olhar Digital noticiou que esses modelos estão sendo utilizados por bandidos para criar golpes com textos mais elaborados. Em 2023, a mídia ficou impactada com a foto do Papa Francisco utilizando uma blusa no estilo Puffer e que foi compartilhada em sites famosos como a Vogue Brasil, mas a verdade mesmo é que essa foto foi gerada pela inteligência artificial generativa do Midjourney.



Figura 3 - Imagem do Papa Francisco utilizando uma blusa Puffer gerada por meio do Midjourney
 Fonte: Inteligência Artificial e ChatGPT: da revolução dos modelos de IA generativa à Engenharia de Prompt [s.d.]

O uso da IA generativa com consciência

Como todo modelo de aprendizado de máquina obtém sua qualidade devido aos dados que são utilizados em seu treinamento, com as IA generativas não funciona diferente. Precisar tomar cuidado sobre como vamos utilizar os dados para alimentar

esses modelos e ainda com privacidade, segurança e direitos autorais. Também devemos nos atentar com os **vieses**.

Os vieses podem ser gerados com base em valores, culturas e interações com o mundo ao nosso redor, e ao treinar um modelo de aprendizado de máquina, deve ser aplicado um olhar mais cuidadoso com os dados de treinamento. Existem muitos exemplos na história de modelos preconceituosos, como por exemplo o caso ocorrido em 2020, na Universidade de Duke, nos Estados Unidos, quando lançaram um modelo de IA para melhorar a resolução de imagens de fotos e um usuário do Twitter inseriu uma foto de baixa qualidade do ex-presidente Barack Obama, onde o modelo recriou a imagem com uma resolução melhorada, mas que mostrava um homem branco de olhos claros.




Figura 4 - Foto original do Barack Obama versus resultado do modelo preconceituoso
 Fonte: Inteligência Artificial e ChatGPT: Da revolução dos modelos de IA generativa à Engenharia de Prompt

Yann LeCun (cientista chefe da Meta, vencedor do prêmio Turing e considerado o pai da área da inteligência artificial e deep learning) publicou em seu perfil do Twitter uma explicação do que teria de fato acontecido. O problema era a base de dados, a qual possuía um viés de amostragem composta majoritariamente por fotos de pessoas brancas.

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, você conheceu quais são os principais desafios éticos quando se trata de IA generativa. Devemos ser profissionais responsáveis e conscientes e prestar a atenção em todos os detalhes ao criar ou gerar uma inteligência artificial generativa, cuidando principalmente da forma como os dados serão coletados e processados, sem nenhum tipo de viés.



REFERÊNCIAS

CARRARO, F. **Inteligência artificial e chatGPT: da revolução dos modelos de IA generativa à engenharia de prompt**. São Paulo: Casa do código, 2023.

EMEND

PALAVRAS-CHAVE

IA generativa. Ética. Segurança. Privacidade. Direitos Autorais.

EUROPE



POSTECH