



SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	11
REFERÊNCIAS.....	12

EMSE

O QUE VEM POR AÍ?

Embarque em uma jornada pela história da tradução, desde seus primórdios até as inovações mais recentes em tradução automática. Explore como a tradução evoluiu ao longo dos milênios, começando com a descoberta da Pedra de Roseta, que desvendou os mistérios dos hieróglifos egípcios, até o papel crucial da tradução na Idade Média e Renascimento. Descubra como o surgimento de dicionários bilíngues no século XVIII transformou a prática da tradução, pavimentando o caminho para avanços significativos no século XX, incluindo a "Tradução Automática Baseada em Regras" e a subsequente evolução para sistemas baseados em estatística e redes neurais.

Esta aula mergulha no impacto de modelos como Word2Vec, Seq2Seq e a arquitetura de atenção, culminando na era das Large Language Models (LLMs), como o GPT-2 e suas versões avançadas, que transformaram a tradução e a compreensão de contextos culturais e linguísticos. Esta viagem oferece uma compreensão detalhada não apenas da história da tradução, mas também das complexidades técnicas e dos desafios enfrentados no campo, ilustrando como a tradução influenciou nosso mundo interconectado.

HANDS ON

Esta aula oferece uma visão ampla sobre a evolução recente da tradução automática, explorando desde a história da tradução até os avanços ocorridos no século XXI. Explore desenvolvimentos técnicos significativos, como a introdução do modelo Word2Vec, a arquitetura Seq2Seq e a inovação trazida pelos sistemas de atenção, que prepararam o terreno para os Grandes Modelos de Linguagem (LLMs), como o GPT-2 e suas versões subsequentes. Compreenda os aspectos técnicos desses modelos, além de questões éticas e práticas relacionadas à sua aplicação em tradução e geração de texto. A aula inclui também demonstrações interativas e convida os participantes a experimentarem por conta própria o impacto e o potencial dessas tecnologias avançadas em diferentes contextos de tradução e localização.

Tenham uma ótima aula!

SAIBA MAIS

A emergência da arquitetura do Transformer no campo do Processamento de Linguagem Natural (PLN) representa um dos avanços mais significativos na história recente da inteligência artificial. Introduzida em 2017 por Vaswani et al. no influente artigo "Attention is All You Need", esta arquitetura revolucionou a maneira como as máquinas entendem e geram linguagem natural. Diferentemente das abordagens anteriores, que dependiam fortemente de redes neurais recorrentes (RNNs) e convolucionais (CNNs), os Transformers introduziram um modelo baseado exclusivamente em mecanismos de atenção, eliminando a necessidade de recorrência sequencial e permitindo um processamento paralelo mais eficiente. Este avanço não apenas melhorou a eficiência computacional, mas também aprofundou a capacidade das máquinas de capturar nuances contextuais em textos extensos.

Antes da introdução dos Transformers, a área de PLN enfrentava desafios significativos, particularmente relacionados à gestão de dependências de longo alcance em textos. Modelos baseados em RNNs, apesar de sua habilidade em processar sequências de dados, eram notoriamente difíceis de treinar devido a problemas como o desvanecimento do gradiente e sua natureza sequencial limitava a paralelização, tornando o processamento de grandes conjuntos de dados uma tarefa lenta. Por outro lado, as CNNs, embora eficientes em capturar padrões locais e permitir paralelização, não eram adequadas para compreender as relações complexas e de longo alcance frequentemente presentes na linguagem humana. Os Transformers superaram essas limitações ao introduzir um mecanismo de atenção que pondera a importância relativa de diferentes partes do texto, permitindo que o modelo avalie o contexto global de uma forma mais eficaz.

A inovação central dos Transformers reside em sua capacidade de processar todos os elementos de uma sequência de entrada simultaneamente, diferentemente das abordagens sequenciais das RNNs. Esta característica, conhecida como "atenção paralela", permite que o modelo avalie e responda a cada parte do texto considerando a relação com todas as outras, uma mudança fundamental que abriu novas possibilidades em termos de compreensão e geração de linguagem. Com essa capacidade, os Transformers podem eficientemente capturar relações complexas e sutis em textos, tornando-os particularmente adequados para tarefas como tradução

automática, resumo de texto, geração de linguagem e muitas outras aplicações de PLN.

Além disso, a arquitetura do Transformer pavimentou o caminho para o desenvolvimento de modelos subsequentes que dominaram o campo. Modelos como BERT (Bidirectional Encoder Representations from Transformers), GPT (Generative Pre-trained Transformer) e outros derivados têm demonstrado desempenho excepcional em uma variedade de benchmarks de PLN, estabelecendo novos padrões para o que as máquinas podem alcançar em termos de compreensão e interação em linguagem natural. Esses desenvolvimentos não apenas marcaram um ponto de virada técnico, mas também abriram novas avenidas para a exploração e aplicação prática de PLN em indústrias e pesquisas.

A arquitetura do Transformer, desde sua concepção, foi projetada para abordar as limitações das redes neurais recorrentes e convolucionais no processamento de sequências, especialmente em tarefas de PLN. Esta seção explora os componentes fundamentais dessa arquitetura inovadora, detalhando como cada elemento contribui para sua capacidade notável de processar e entender a linguagem natural.

O coração do Transformer é o mecanismo de atenção multi-cabeça. Diferente das abordagens anteriores que processavam sequências de maneira linear, o Transformer analisa várias partes de uma sequência simultaneamente. Cada "cabeça" de atenção no modelo foca em diferentes partes da sequência de entrada, permitindo que o modelo capture uma gama mais ampla de relações contextuais. Por exemplo, em uma frase, enquanto uma cabeça pode focar na relação entre sujeito e verbo, outra pode analisar a conexão entre adjetivos e substantivos. Essa abordagem paralela não só melhora a eficiência do processamento, mas também enriquece a compreensão contextual do modelo.

Dessa forma, o mecanismo de atenção é peça central para o Transformer, determinando o grau de foco que cada palavra da sequência de entrada deve receber. O modelo calcula scores de atenção, que são essencialmente medidas de relevância entre pares de palavras. Esses scores são obtidos por meio de produtos escalares entre vetores de consulta (query), chave (key) e valor (value), seguidos pela aplicação da função softmax para normalização. Esse processo permite que o Transformer avalie cada palavra no contexto de todas as outras, diferentemente das RNNs, que processam sequencialmente e podem perder informações contextuais de longo

alcance. Por exemplo, considere a frase “O livro é azul”. O mecanismo de atenção daria um peso maior para as palavras “livro” e “azul”, pois elas contêm mais informação que as palavras “O” e “é”.

Dentro de cada bloco do Transformer, após a camada de atenção, há uma rede feedforward densamente conectada. Essa rede é aplicada a cada posição separadamente e de forma idêntica. Composta por duas camadas lineares com uma ativação não-linear entre elas, a rede feedforward é responsável por transformar a representação contextualizada obtida pela atenção em uma nova representação, que será passada para o próximo bloco do Transformer. Essa etapa é crucial para a aprendizagem de representações mais complexas e abstratas da linguagem.

Para evitar o problema do desaparecimento do gradiente em redes profundas, o Transformer utiliza conexões residuais em torno de cada uma das subcamadas, incluindo as camadas de atenção e as redes feedforward. Essa não é uma abordagem especialmente nova: ela já foi muito bem testada e existe desde as ResNets que são amplamente usadas para classificação de imagens. Essas conexões também permitem que o modelo preserve informações de camadas anteriores, adicionando-as à saída das subcamadas. Além disso, cada subcamada no Transformer é seguida por uma normalização em camadas, que estabiliza o processo de aprendizagem ao normalizar a saída de cada subcamada.

Esses componentes fundamentais trabalham em conjunto para dar ao Transformer sua capacidade única de processar sequências de linguagem natural. Ao contrário das RNNs e CNNs, que têm limitações inerentes na captura de dependências de longo alcance e na paralelização, o Transformer supera esses desafios com sua arquitetura inovadora, estabelecendo um novo padrão para o processamento de linguagem natural.

Depois de montada a arquitetura, seguimos para o treinamento do Transformer. O treinamento eficaz de modelos de linguagem baseados em Transformer é um processo complexo e multifacetado. Esta seção aborda as metodologias e técnicas utilizadas para treinar esses modelos avançados, destacando as nuances e desafios envolvidos.

Esse processo começa com o backpropagation, uma técnica fundamental para o aprendizado em redes neurais profundas. Durante o treinamento, o modelo tenta

prever a próxima palavra em uma sequência com base no contexto fornecido pelas palavras anteriores. O erro gerado pela diferença entre a previsão e o valor real é, então, utilizado para ajustar os pesos da rede. Esse processo é iterativo e ocorre em várias camadas do Transformer, refinando gradualmente sua capacidade de entender e gerar linguagem natural.

Transformers podem ser treinados usando abordagens supervisionadas e não supervisionadas. No treinamento supervisionado, o modelo é treinado com pares de entrada e saída bem definidos, como textos e suas traduções correspondentes. Isso permite que o modelo aprenda relações diretas entre as sequências de entrada e saída.

Por outro lado, no treinamento não supervisionado, o modelo é exposto a grandes volumes de texto sem anotações específicas. Aqui, o objetivo é que o modelo aprenda a estrutura e a dinâmica da linguagem de forma autônoma, capturando nuances e padrões intrínsecos ao texto. Modelos gerais, como o GPT, BERT e o Gemini, são treinados de forma não supervisionada.

O treinamento de Transformers apresenta vários desafios. Primeiramente, devido ao seu tamanho e complexidade, esses modelos requerem uma quantidade significativa de dados e poder computacional. Além disso, o ajuste fino dos hiperparâmetros, como número de camadas, tamanho dos lotes de treinamento e taxas de aprendizado, é crucial para o sucesso do treinamento. Outro desafio é garantir que o modelo não apenas memorize os dados de treinamento (overfitting), mas também generalize bem para novos dados (generalização).

Para ilustrar o processo de treinamento, podemos considerar o exemplo do GPT-3, um modelo de Transformer amplamente conhecido. O GPT-3 foi treinado em um dataset diversificado, incluindo livros, artigos e sites, totalizando 45 terabytes de texto. O treinamento envolveu a previsão da próxima palavra em milhões de sequências de texto, permitindo que o modelo desenvolvesse uma compreensão abrangente da linguagem natural. Este processo ilustra a escala e a complexidade envolvidas no treinamento de modelos de linguagem de última geração.

O treinamento de Transformers é, portanto, uma tarefa intensiva que requer recursos consideráveis, geralmente do nível de datacenters dedicados, com centenas ou milhares de GPUs disponíveis. Porém, o resultado são modelos capazes de

realizar tarefas de PLN com uma eficiência e precisão sem precedentes, com exemplos na área de tradução automática, localização, geração de textos, análise de sentimentos e até mesmo chatbots e assistentes virtuais inteligentes.

Discutindo um pouco sobre os desafios e limitações dos modelos, um dos maiores desafios associados aos Transformers, especialmente modelos de grande escala como o GPT-3, é justamente o alto custo computacional. O treinamento desses modelos exige uma quantidade substancial de recursos de computação, como GPUs de alto desempenho, e um consumo significativo de energia. Isso não apenas eleva os custos financeiros, mas também levanta preocupações ambientais devido à grande pegada de carbono associada ao uso intensivo de energia. Pesquisadores estão explorando maneiras de tornar o treinamento de Transformers mais eficiente, incluindo técnicas como treinamento distribuído e otimização de arquitetura.

Outra limitação dos Transformers é a tendência de "alucinar" informações durante a geração de texto, ou seja, produzir respostas que são plausíveis, mas incorretas ou não baseadas em fatos. Essa questão é particularmente desafiadora em tarefas que exigem precisão e confiabilidade, como na geração de respostas informativas ou na síntese de dados. Abordagens para mitigar esse problema incluem o refinamento de técnicas de treinamento, a introdução de mecanismos de verificação de fatos e a combinação de Transformers com sistemas baseados em regras ou conhecimento estruturado. Um método que se destacou no último semestre de 2023 foi o RAG (Retrieval Augmented Generation).

A capacidade de generalizar para novos dados é um desafio crítico para os Transformers. Enquanto esses modelos são treinados em grandes conjuntos de dados, eles podem falhar em generalizar para situações ou contextos não vistos durante o treinamento. Além disso, há o risco de overfitting, onde o modelo se torna excessivamente especializado nos dados de treinamento e perde a capacidade de se adaptar a novos dados ou tarefas. Pesquisadores estão investigando abordagens como o aumento de dados e técnicas de regularização para melhorar a generalização dos modelos.

Outra preocupação é que os modelos de linguagem, incluindo os baseados em Transformer, podem perpetuar e amplificar vieses presentes nos dados de treinamento. Isso levanta questões éticas significativas, especialmente quando os modelos são aplicados em contextos sociais sensíveis. A pesquisa em ética de IA e

PLN está focada em desenvolver métodos para detectar, mitigar e prevenir vieses nos modelos, garantindo que as aplicações de PLN sejam justas e não discriminatórias.

Por último, mas não menos importante, a complexidade e a natureza "caixa-preta" dos Transformers levantam desafios de interpretabilidade. Entender como esses modelos tomam decisões específicas ou chegam a certas conclusões é crucial para a confiança e a adoção em aplicações críticas. A pesquisa em interpretabilidade de IA está focada em tornar os modelos de Transformer mais transparentes e compreensíveis para os usuários e desenvolvedores.

Esses desafios destacam que, embora os Transformers tenham transformado o campo do PLN, ainda há um caminho significativo a ser percorrido em termos de eficiência, confiabilidade e ética.

Finalizando, os Transformers representam um marco no desenvolvimento de tecnologias de Processamento de Linguagem Natural, oferecendo ferramentas poderosas para uma ampla gama de aplicações. Como discutimos, existem diversos desafios e limitações, mas o campo de pesquisa está avançando rapidamente e os benefícios potenciais desses modelos para a sociedade são imensos. À medida que continuamos a explorar e aprimorar essas tecnologias, podemos esperar descobertas e inovações ainda mais impressionantes no futuro.

O QUE VOCÊ VIU NESTA AULA?

Essa aula forneceu uma visão abrangente e detalhada sobre a evolução da tradução ao longo da história, destacando importantes marcos e desenvolvimentos tecnológicos. A narrativa começa com referência à Pedra de Roseta, um artefato arqueológico crucial para a decifração dos hieróglifos egípcios. Em seguida, aborda o papel da tradução na disseminação do conhecimento durante a Idade Média e o Renascimento.

Já no século XX, vimos avanços significativos com a introdução da "Tradução Automática Baseada em Regras", que usava regras gramaticais e lexicais fixas para traduzir textos. Este método, apesar de tecnicamente correto, enfrentava desafios com estruturas linguísticas complexas e a necessidade de atualização constante das regras em todos os idiomas.

Vimos, então, o desenvolvimento dos bancos de dados de tradução e a evolução para a "Tradução Automática Baseada em Exemplos", seguida pela introdução de sistemas de tradução baseados em estatística, na década de 1990. Essa evolução permitiu o rápido treinamento de redes neurais e o modelo Word2Vec de Tomáš Mikolov, em 2012, que representou um avanço significativo na compreensão e tradução de linguagens.

Também vimos o sistema Seq2Seq e, por último, a arquitetura de atenção que foram outros marcos importantes na tradução automática, com o "Google Neural Machine Translation" (GMNT), de 2016, sendo um exemplo notável. Finalmente, discutimos o papel das LLMs (Large Language Models), como o GPT-2 e suas versões subsequentes na tradução e na compreensão de contextos culturais e linguísticos.

REFERÊNCIAS

BROWN, T., et al. **Language Models are Few-Shot Learners**. 2020. Disponível em: <https://arxiv.org/abs/2005.14165>. Acesso em: 26 mar. 2024.

DEVLIN, J., et al. **BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding**. 2018. Disponível em: <https://arxiv.org/abs/1810.04805>. Acesso em: 26 mar. 2024.

VASWANI, A., et al. **Attention is All You Need**. 2017. Disponível em: <https://arxiv.org/abs/1706.03762>. Acesso em: 26 mar. 2024.

PALAVRAS-CHAVE

Transformers. Tradução. Localização.

EMANIP



POSTECH