



SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	14
REFERÊNCIAS.....	15

EMSE

O QUE VEM POR AÍ?

Vamos falar dos Grandes Modelos de Linguagem (ou LLMs) e sua aplicação em Tradução Automática e Localização. Você vai descobrir como os LLMs e como o GPT-4, da OpenAI, revolucionaram a tradução e a localização, permitindo uma compreensão e adaptação cultural muito além das capacidades das redes recorrentes anteriores. Vamos ver o impacto transformador dos LLMs na indústria tecnológica, desde a localização de softwares e aplicativos, até a documentação técnica e suporte on-line.

Além disso, você também vai descobrir a importância dos LLMs em testes de software, especialmente em testes de localização, e verá como eles são cruciais para a adaptação de marketing em diferentes contextos culturais e linguísticos. Ainda nesta aula, vamos explorar o fascinante mundo da localização em imagens, utilizando técnicas como "inpainting" em LLMs e modelos de difusão para adaptar conteúdo visual a diferentes públicos.

HANDS ON

Esta aula oferece uma compreensão abrangente dos desafios e potenciais dos LLMs na tradução e localização, com demonstrações interativas para ilustrar seu impacto em diversos contextos.

Tenha uma ótima aula!

EMEND

SAIBA MAIS

Nesta aula, trouxemos para vocês o artigo “Multilingual Machine Translation with Large Language Models: Empirical Results and Analysis”, de 2023, que é bastante atual. Ele ainda não foi publicado em nenhuma revista e, portanto, ainda não foi revisado por pares. Mas, nessa terceira versão, de 29 de outubro de 2023, já é um artigo bastante polido sobre tradução automática.

O artigo explica que os modelos de linguagem de grande escala (LLMs), devido ao seu tamanho e quantidade de dados de treinamento, estão se mostrando muito eficazes em várias tarefas, incluindo a tradução automática (MT). Esses modelos conseguem aprender e realizar tarefas a partir de exemplos e instruções dadas pelos usuários, um processo conhecido como aprendizado em contexto (ICL). Um exemplo notável de sucesso desses modelos é a tradução de idiomas utilizando-se de muitos recursos, como a tradução inglês-alemão.

Entretanto, o artigo destaca que a capacidade dos LLMs em tradução multilíngue ainda não foi totalmente explorada. A tradução multilíngue (MMT) é complexa, pois envolve traduzir textos entre diferentes idiomas, exigindo alinhamento semântico entre eles. Ainda é incerto como os LLMs adquirem a habilidade de traduzir e quais fatores influenciam essa habilidade.

O objetivo do estudo é investigar a performance dos LLMs em MMT, respondendo a duas perguntas principais:

1ª) Como os LLMs realizam MMT em uma ampla gama de idiomas?

2ª) Quais fatores afetam o desempenho dos LLMs em MMT?

Para isso, os autores avaliaram vários LLMs populares, incluindo modelos focados em inglês, como OPT e Falcon, e modelos multilíngues, como XGLM, BLOOMZ e GPT-4, considerando 102 idiomas em 606 direções de tradução.

Os resultados mostraram que a capacidade de tradução multilíngue dos LLMs está melhorando, com o GPT-4 alcançando um novo patamar de desempenho. Comparado com sistemas de MMT supervisionados, como o NLLB, o GPT-4 teve um desempenho superior em várias direções de tradução centradas no inglês. No entanto, em comparação com sistemas comerciais, como o Google Translator, os

LLMs ainda têm um longo caminho a percorrer, especialmente com idiomas de poucos recursos, como observado na Figura 1. Traduções centradas em francês e chinês se mostraram mais desafiadoras para o GPT-4 do que aquelas centradas em inglês, indicando uma capacidade desigual entre idiomas.




Figura 1 - Desempenho de tradução multilíngue (tradução do inglês para outro idioma)
Fonte: elaborado pelo autor (2024), adaptado por FIAP (2024)

A pesquisa também descobriu novos padrões de funcionamento do ICL em LLMs para MMT. Primeiro, mesmo com instruções não razoáveis, os LLMs conseguem realizar traduções se fornecidos os exemplos adequados. No entanto, se os exemplos dados não corresponderem ao ideal, os LLMs falham na tradução. Segundo, os pares de tradução entre idiomas diferentes podem ser exemplos surpreendentemente bons para traduções de idiomas de poucos recursos. Terceiro, os LLMs podem adquirir habilidades de tradução de maneira eficiente em termos de recursos, mesmo para idiomas sem recursos prévios.

As principais contribuições do artigo são:

1ª) Avaliar LLMs populares em MMT para 102 idiomas e 606 direções de tradução.

2ª) Comparar sistematicamente os resultados dos LLMs com três bases supervisionadas fortes (M2M-100, NLLB, Google Translator) e destacar a lacuna entre os dois paradigmas de tradução.

3ª) Encontrar novos padrões de funcionamento do ICL para MMT em LLMs e discutir vantagens e desafios correspondentes.

Na sequência, esse trabalho descreve que a modelagem de linguagem é uma tarefa fundamental no processamento de linguagem natural (PLN), cujo objetivo é prever a probabilidade do próximo elemento (token) em um texto. A arquitetura conhecida como Transformer, introduzida em 2017, é a base dos atuais modelos de linguagem de grande escala (LLMs).

Os LLMs têm se mostrado extremamente eficientes como aprendizes universais para várias tarefas. Estudos recentes revelaram que, ao aumentar o tamanho dos parâmetros neurais e dos dados de treinamento, os LLMs se tornam ainda mais potentes. Um exemplo dessa evolução é a capacidade de "aprendizado em contexto", uma habilidade notável que surge apenas em modelos de grande escala. Esforços contínuos têm sido feitos para aumentar o tamanho desses modelos, resultando em sistemas como o GPT-4 e o ChatGPT da OpenAI, que apresentam resultados impressionantes em diversas tarefas de PLN.

O "aprendizado em contexto" é uma habilidade emergente nos LLMs, ou seja, uma habilidade para a qual eles não foram explicitamente treinados. Essa habilidade permite que os modelos aprendam e executem tarefas específicas baseadas em instruções fornecidas, sem a necessidade de atualizar seus parâmetros internos. Esse processo envolve o uso de exemplos em contexto (exemplares) e um modelo de instruções (template).

Os exemplares são frequentemente selecionados de dados supervisionados, onde cada par (X_i, Y_i) consiste em uma frase de entrada X_i e sua correspondente verdadeira Y_i . O template T é uma instrução escrita por humanos relacionada à tarefa-alvo. A combinação dos exemplares com o template gera o prompt final. Durante a inferência, o LLM gera a saída correspondente Y para uma amostra de teste X , guiado pelo prompt.

Para tarefas de previsão de labels, a previsão Y pode ser obtida em uma única etapa de geração. Já para tarefas de geração de sequência, como a tradução automática, a previsão Y pode ser obtida por meio de estratégias de amostragem, como busca gulosa ou busca em feixe.

Na sequência, os autores detalham a configuração dos experimentos realizados para avaliar a eficácia dos modelos de linguagem de grande escala (LLMs) na tradução automática multilíngue.

O estudo utiliza o dataset FLORES-101, desenvolvido por Goyal et al. (2022), que é adequado para avaliar a qualidade dos modelos em uma ampla variedade de idiomas. Esse dataset é significativo por sua diversidade, incluindo idiomas com recursos variados. Oito LLMs populares são avaliados:

- XGLM-7.5B (Lin et al., 2022)
- OPT-175B (Zhang et al., 2022)
- BLOOMZ-7.1B (Scao et al., 2022)
- Falcon-7B (Almazrouei et al., 2023)
- LLaMA2-7B (Touvron et al., 2023)
- LLaMA2-7B-chat (Touvron et al., 2023)
- ChatGPT (OpenAI, 2022)
- GPT-4 (OpenAI, 2023)

Esses modelos representam o estado da arte em termos de capacidade de processamento de linguagem e são selecionados devido ao seu desempenho anteriormente demonstrado em tarefas diversas de PLN.

Para cada modelo, o desempenho de tradução é avaliado usando oito (8) pares de tradução aleatoriamente selecionados do conjunto de desenvolvimento correspondente, como exemplos em contexto e o template "<X>=<Y>" para estruturar os prompts. Os placeholders "<X>" e "<Y>" representam, respectivamente, a frase fonte e a frase alvo. A implementação baseia-se no OpenICL (WU et al., 2023). A estratégia de ICL é considerada simples, mas eficaz, segundo a análise dos experimentos.

O desempenho é também comparado a modelos supervisionados amplamente utilizados em MMT, incluindo:

- M2M-100-12B (Fan et al., 2021)
- NLLB-1.3B (Costa-jussà et al., 2022) (versão de destilação)

E com o sistema de tradução comercial Google Translator.

Já com relação à avaliação, as métricas utilizadas incluem o SentencePiece BLEU (spBLEU), conforme sugerido por (GOYAL et al. 2022), que permite avaliar todos os idiomas. Além disso, métricas emergentes como COMET (REI et al., 2020) e SCScore (XU et al., 2022) são utilizadas, pois mostraram boa correlação com julgamentos humanos. Essas métricas são importantes para uma avaliação abrangente e justa da qualidade da tradução.

Na sequência, o trabalho apresenta os resultados da avaliação da capacidade de tradução automática multilíngue dos Modelos de Linguagem de Grande Escala (LLMs) e discutem suas principais descobertas.

Os LLMs demonstraram uma impressionante habilidade de tradução multilíngue, mesmo aqueles treinados apenas em um idioma, sugerindo a possibilidade de alinhar múltiplos idiomas com dados não supervisionados. Os LLMs mais recentes, como LLaMA2-7B e GPT-4, mostraram avanços significativos nessa área. O GPT-4, em particular, se destaca como o melhor tradutor entre os modelos avaliados, alcançando as maiores pontuações médias em BLEU e COMET na maioria das direções de tradução.

Os LLMs tendem a ter um desempenho melhor em traduções para o inglês do que para outros idiomas. A capacidade de tradução em idiomas não ingleses é desigual. Por exemplo, os LLMs têm resultados impressionantes em idiomas indo-europeus-germânicos, que são semelhantes ao inglês, mas apresentam resultados menos satisfatórios em idiomas dissimilares, como os sino-tibetanos.

Em comparação com sistemas de tradução supervisionados, os LLMs ainda estão atrás, especialmente em idiomas com poucos recursos. O GPT-4 superou o modelo supervisionado NLLB em 40,91% das direções de tradução, mas ainda fica aquém em idiomas menos comuns.

Os autores também abordam a preocupação com o vazamento de dados ao avaliar LLMs em datasets públicos. Por exemplo, o BLOOMZ foi excluído do relatório de desempenho no FLORES-101, pois foi treinado com um dataset que inclui o FLORES-200, o que poderia ter exposto o modelo a casos de teste durante o treinamento. Para ilustrar essa preocupação, os autores criaram um conjunto de avaliação “NEWS2023”, composto por traduções de notícias recentes. O BLOOMZ mostrou uma deterioração significativa no desempenho neste novo conjunto, enquanto outros modelos mantiveram um desempenho consistente, destacando o risco de vazamento de dados ao avaliar LLMs.

Após isso, é explorado como os Modelos de Linguagem de Grande Escala adquirem a habilidade de tradução e quais fatores influenciam seu desempenho. É escolhido o XGLM-7.5B como exemplo por três razões principais: seu foco multilíngue, seu tamanho médio e acessibilidade para experimentos e a clareza na composição de seu corpus de pré-treinamento.

É investigada a relação entre o desempenho de tradução e o tamanho do corpus de pré-treinamento. O trabalho discute que para idiomas com poucos recursos, como catalão e suaíli, o XGLM consegue gerar traduções moderadas, mesmo com poucos recursos monolíngues não ingleses. Isso mostra que os LLMs podem construir mapeamentos bilíngues de maneira eficiente em termos de recursos. Mesmo em idiomas não vistos, como occitano e asturiano, o XGLM consegue traduzir por meio do aprendizado em contexto. Essas observações indicam uma vantagem potencial do novo paradigma de tradução: os LLMs aprendem a traduzir de forma eficiente em termos de recursos.

Mas o desempenho dos LLMs depende de um template bem projetado? No paper, é discutido que o desempenho de tradução varia significativamente com diferentes templates. O template “<X>=<Y>” alcança a maior pontuação média em BLEU, enquanto “[SRC]: <X> \n [TGT]: <Y>” obtém a menor pontuação, embora seja comumente utilizado em outros LLMs. Isso indica que o template desempenha um papel vital no aprendizado em contexto e pode ser desafiador projetar um template universalmente ótimo para diferentes LLMs e direções de tradução.

Muito interessante é que até templates aparentemente sem sentido podem instruir os LLMs a gerar traduções razoáveis. Por exemplo, um template como “<X> pode ser resumido como <Y>” também pode instruir o LLM a gerar tradução, em vez

de resumo. Essa descoberta sugere que a comunidade pode não entender completamente o papel do template em contexto.

É discutido também se usar exemplares interlinguísticos pode ajudar em certas direções de tradução. Por exemplo, na tradução chinês-inglês de baixos recursos, o uso desses exemplares melhora significativamente o desempenho, mesmo quando tanto a língua fonte, quanto a língua alvo são alteradas. No entanto, para a tradução alemão-inglês, o desempenho de tradução piora com o uso de exemplares interlinguísticos. Isso sugere um potencial para o uso de exemplares interlinguísticos em uma gama mais ampla de tarefas.

Também são comparados diferentes métodos de seleção de exemplares, incluindo seleção aleatória e seleção baseada em semelhança semântica. O trabalho discute que exemplares semanticamente relacionados não trazem mais benefícios do que os escolhidos aleatoriamente. A performance de tradução permanece similar independente da estratégia de seleção, mesmo quando muitos exemplares são utilizados.

Os exemplares ensinam aos LLMs as características centrais da tarefa de tradução. Por exemplo, quando exemplares de tradução incompatíveis são usados, os LLMs falham completamente, indicando a necessidade de exemplares consistentes para manter a coerência semântica entre as frases fonte e alvo. Além disso, a granularidade da tradução nos exemplares também é importante, assim como a sua diversidade. Exemplares duplicados resultam em um desempenho inferior, reforçando a importância de ter exemplares variados.

Uma descoberta interessante é que os exemplares localizados na parte final do prompt têm um impacto maior no comportamento do LLM. Experimentos mostram que inverter a direção da tradução nos exemplares na cauda do prompt resulta em um desempenho pior do que fazer o mesmo com os exemplares no início.


Por último, temos a conclusão do paper. Nela, destaca-se que as capacidades de tradução dos LLMs estão continuamente melhorando, com o GPT-4 alcançando um novo patamar de desempenho. No entanto, mesmo o GPT-4 ainda enfrenta desafios em idiomas com poucos recursos.

Além disso, a análise revelou padrões de trabalho inovadores dos LLMs quando aplicados à tradução automática multilíngue. Por exemplo, descobriu-se que a

semântica das instruções pode ser ignorada durante o aprendizado em contexto e que exemplares interlinguísticos podem oferecer melhores instruções para a tradução em idiomas com poucos recursos.

Uma conclusão importante é que usando diferentes técnicas LLMs podem se adquirir habilidades de tradução de maneira mais eficiente, mesmo que se tenha menos recursos. Isso sugere um futuro promissor para os LLMs no campo da tradução automática multilíngue, especialmente em termos de acessibilidade e aplicabilidade em uma variedade mais ampla de idiomas.

Na Figura 2, temos um dos gráficos mais representativos da capacidade de tradução de diferentes LLMs em diversos idiomas.






Figura 2 - Resultados de comparação entre os LLMs avaliados em diferentes famílias linguísticas
Fonte: elaborado pelo autor (2024), adaptado por FIAP (2024)

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, continuamos trabalhando com os Grandes Modelos de Linguagem (ou LLMs), com foco especial na sua aplicação em Tradução Automática e Localização, destacando o papel do GPT-4 da OpenAI. Inicialmente, discutimos como os LLMs revolucionaram o campo da tradução automática, superando as limitações das redes neurais recorrentes anteriores. Eles introduziram a capacidade de aprender e interpretar contextos mais longos, permitindo uma tradução mais precisa e contextualizada. Isso é particularmente relevante na localização, onde não apenas a linguagem, mas também os aspectos culturais devem ser considerados para adaptar o conteúdo a diferentes realidades. Destacamos o impacto significativo dos LLMs na indústria tecnológica, especialmente na tradução e adaptação cultural de softwares, aplicativos, documentação técnica e suporte on-line.

Prosseguindo, abordamos superficialmente técnicas avançadas usadas para treinar chatbots especializados em atendimento ao cliente, como Engenharia de Prompt e Geração Aumentada por Recuperação (RAG), que serão trabalhadas com mais profundidade em aulas futuras. Esses métodos permitem que os chatbots respondam de maneira eficiente e em vários idiomas, melhorando a interação com o usuário. Além disso, discutimos a importância dos LLMs nos testes de software, particularmente nos testes de localização. Esses testes são cruciais para garantir que os produtos funcionem corretamente em diferentes configurações linguísticas e culturais, identificando problemas como incompatibilidade com caracteres específicos de idiomas ou a necessidade de adaptação de unidades de medida.

Por fim, exploramos o uso de LLMs na localização de marketing e na adaptação de conteúdo para diferentes públicos, destacando a necessidade de não apenas traduzir, mas também adaptar o material para ressoar com as preferências e sensibilidades culturais locais. Além disso, discutimos a aplicação de LLMs e outras tecnologias, como o Dalle e o Stable Diffusion, na localização de imagens. Essas ferramentas permitem modificar imagens para se adequarem a diferentes contextos culturais, usando técnicas como "inpainting" e modelos de difusão.

REFERÊNCIAS

CHAUDHARY, V. et al. **The Flores-101 evaluation benchmark for low-resource and multilingual machine translation**. Transactions of the Association for Computational Linguistics (TACL), 2021. Disponível em: <https://arxiv.org/abs/2106.03193>. Acesso em: 22 mar. 2024.

CHEN, J. et al. **Multilingual Machine Translation with Large Language Models: Empirical Results and Analysis**. 2023. Disponível em: <https://arxiv.org/abs/2304.04675>. Acesso em: 27 mar. 2024.

FAN, A.; et al. **Beyond english-centric multilingual machine translation**. The Journal of Machine Learning Research (JMLR), 2020. Disponível em: <https://arxiv.org/abs/2010.11125>. Acesso em: 22 mar. 2024.

PALAVRAS-CHAVE

Transformers. Benchmark de modelos. Tradução. Localização.

EMEND



POSTECH