

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS	5
O QUE VOCÊ VIU NESTA AULA?	10
REFERÊNCIAS.....	11

EMSE

O QUE VEM POR AÍ?

Nesta aula, aprenderemos sobre os Document Loaders no LangChain, que são ferramentas essenciais para carregar e manipular diferentes tipos de dados em aplicações de inteligência artificial.

EMEND

HANDS ON

Nesta aula prática, veremos alguns exemplos de como utilizar os Document Loaders no LangChain para carregar e manipular diferentes tipos de dados. Exploraremos como conectar a fontes como PDFs, CSV, Text e páginas web.

EXEMPLO

SAIBA MAIS

Os **Document Loaders** no LangChain são responsáveis por carregar documentos e dados de diversas fontes, como PDFs, CSV, páginas web, bancos de dados SQL, entre outros. Eles permitem que as pessoas desenvolvedoras integrem facilmente dados de diferentes formatos e fontes às suas aplicações, garantindo uma interface padronizada para manipular essas informações.

Essa funcionalidade é essencial para aplicações que dependem da análise de documentos extensos ou fontes de dados diversas, pois os **Document Loaders** simplificam a manipulação desses arquivos, reduzindo a necessidade de código específico para cada tipo de dado.

O LangChain oferece vários tipos de **Document Loaders**, cada um especializado em um formato de documento ou fonte de dados. A seguir listamos alguns dos mais utilizados:

- **PDF Loaders**: utilizado para carregar e manipular arquivos PDF.
- **CSV Loaders**: carrega e manipula dados em formato CSV.
- **WebBaseLoader**: faz o scraping de páginas web e carrega o conteúdo.
- **NotionDirectoryLoader**: carrega dados armazenados no Notion.

Para ficar mais claro, veremos uma implementação básica de cada um deles.

Iniciando pelo **PDF Loader**, temos um exemplo simples onde utilizamos o **PyPDFLoader** para carregar e manipular o conteúdo de um arquivo PDF. O objetivo é carregar o arquivo, contar o número de páginas ou documentos que foram extraídos e exibir o conteúdo dessas páginas, permitindo que o arquivo seja processado por um modelo de linguagem posteriormente.

Vejamos um exemplo de código demonstrando como podemos trabalhar com PDF:

```
from langchain.document_loaders import PyPDFLoader

caminho_pdf = "exemplo1.pdf"
```

```
loader = PyPDFLoader(caminho_pdf)

documentos = loader.load()

print(f"Número de documentos carregados: {len(documentos)}")

for i, documento in enumerate(documentos):
    print(f"\nConteúdo da página {i + 1}:")
    print(documento.page_content)
```

Agora, vejamos um exemplo de como utilizar o **CSV Loader** no LangChain para carregar e manipular dados em formato CSV:

Arquivo .csv

```
Nome,Idade,Profissão
Maria,30,Engenheira
João,25,Designer
Ana,40,Gerente
```

Código:

```
from langchain.document_loaders import CSVLoader

caminho_csv = "exemplo.csv"

loader = CSVLoader(caminho_csv)

documentos = loader.load()

print(f"Número de documentos carregados: {len(documentos)}")
```

```
for i, documento in enumerate(documentos):  
    print(f"\nConteúdo da linha {i + 1}:")  
    print(documento.page_content)
```

Explicação:

1. **CSVLoader**: usamos o CSVLoader para carregar o arquivo CSV especificado. Ele transforma cada linha do CSV em um “documento” que pode ser manipulado.
2. **loader.load()**: carrega o conteúdo do CSV e o organiza como objetos de documento. Cada linha do CSV é tratada como um documento separado.
3. **Exibição do Conteúdo**: para cada documento (linha) carregado, exibimos o conteúdo correspondente.

Avançando com **WebBaseLoader**, ele automatiza o processo de coleta de dados, logo, é possível automatizar a captura de conteúdo de páginas da web e processá-lo dentro do **LangChain**, facilitando a criação de fluxos de trabalho que envolvem análise de texto, geração de resumos ou até mesmo treinamento de modelos de linguagem com base em informações extraídas diretamente da internet.

A seguir, veremos um exemplo prático de como utilizar o **WebBaseLoader** para carregar dados de uma página web, dividindo o conteúdo em seções e permitindo que ele seja manipulado para uso posterior.

Se você está construindo uma aplicação que precisa de dados de uma página de notícias, o **WebBaseLoader** pode carregar a URL da página, extraindo o texto para que seja possível realizar análises.

Aqui está um exemplo simples, onde carregamos uma página e exibimos seu conteúdo:

```
from langchain.document_loaders import WebBaseLoader  
  
url = "https://en.wikipedia.org/wiki/Artificial_intelligence"  
  
loader = WebBaseLoader(url)
```

```
documentos = loader.load()

print(f"Número de seções carregadas: {len(documentos)}")

for i, documento in enumerate(documentos):
    print(f"\nConteúdo da seção {i + 1}:")
    print(documento.page_content)
```

Analisando este trecho de código, nós temos:

1. **Importação do WebBaseLoader:** carrega a classe responsável por extrair dados de uma página web.
2. **Definir a URL:** a URL da página que será carregada é definida (neste caso, a página da Wikipédia sobre inteligência artificial).
3. **Criar o Loader:** um objeto **WebBaseLoader** é criado, que será usado para carregar o conteúdo da página.
4. **Carregar o conteúdo:** o método `load()` é chamado para extrair o conteúdo da página e dividi-lo em "documentos" (geralmente correspondentes a seções da página).
5. **Exibir o Número de Seções:** exibe o número de seções ou blocos de conteúdo que foram carregados da página.
6. **Iterar sobre o Conteúdo:** o código percorre cada seção da página e imprime o conteúdo extraído de cada uma.

O **NotionDirectoryLoader** é uma ferramenta poderosa do LangChain que permite carregar dados diretamente de uma conta ou diretório do Notion.

Para quem não conhece, o **Notion** é uma plataforma popular para organização de dados e projetos, sendo amplamente utilizada para notas, tarefas e gerenciamento de conteúdo. Integrar esses dados em fluxos de trabalho de inteligência artificial com LangChain oferece grande flexibilidade, permitindo a automatização de análises e processamento de informações armazenadas no Notion.

Por meio do **NotionDirectoryLoader**, você pode carregar páginas, bases de dados e outras informações armazenadas no Notion para análise ou processamento

utilizando **Large Language Models (LLMs)**, criando uma integração perfeita entre as anotações organizacionais e fluxos de trabalho de IA.

Vejamos um exemplo onde carregaremos dados de um diretório do Notion, usando a API do Notion para acessar o conteúdo de uma conta e manipulá-lo:

```
from langchain_community.document_loaders import NotionDirectoryLoader
from dotenv import load_dotenv
import os

load_dotenv()

notion_diretorio = "id da pagina"

loader = NotionDirectoryLoader(notion_diretorio)

documentos = loader.load()

print(f"Número de documentos carregados: {len(documentos)}")

for i, documento in enumerate(documentos):
    print(f"\nConteúdo do documento {i + 1}:")
    print(documento.page_content)
```

Para executar este código, é necessário utilizar um token da API do Notion, que você pode criar acessando o próprio [site da ferramenta](#), e caso tenha interesse em saber mais sobre esse pacote do LangChain, temos um [link da documentação](#).

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, aprendemos sobre os **Document Loaders** no LangChain, ferramentas essenciais para carregar e manipular diferentes tipos de dados em aplicações de inteligência artificial. Exploramos como utilizar loaders para **PDFs**, **CSV**, **páginas web** e **Notion**.



REFERÊNCIAS

DOCUMENT loaders. **langchain**. 2023. Disponível em: https://python.langchain.com/v0.1/docs/modules/data_connection/document_loaders/. Acesso em: 06 set. 2024.


NGUONLY, A. A Guide to Gotchas with LangChain Document Loaders in a Chrome Extension. **Medium**. 2024. Disponível em: <https://medium.com/@andrewnguonly/a-guide-to-gotchas-with-langchain-document-loaders-in-a-chrome-extension-6228369f79f6>. Acesso em: 06 set. 2024.

SAKAMOTO, A. Get Started with LangChain Document Loaders: A Step-by-Step Guide. **kanaries**. 2023. Disponível em: <https://docs.kanaries.net/topics/LangChain/langchain-document-loader>. Acesso em: 06 set. 2024.

PALAVRAS-CHAVE

Palavras-chave: Document Loaders. CSV Loader. PDF Loader.

EMSE



POSTECH